T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

BSM 498 BİTİRME ÇALIŞMASI

YAPAY ZEKA DESTEKLİ OTOMATİK VİDEO DUBLAJ VE ALTYAZI ÜRETİM SİSTEMİ

G221210056– Azra Nur Tekbaş

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ
Tez Danışmanı : Dr.Öğr.Üyesi Ulaş YURTSEVER

2025–2026 Bahar Dönemi

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

YAPAY ZEKA DESTEKLİ OTOMATİK VİDEO DUBLAJ VE ALTYAZI ÜRETİM SİSTEMİ

BSM 498 - BİTİRME ÇALIŞMASI

G221210056– Azra Nur Tekbaş

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ

Bu tez .... / .... / ..... tarihinde aşağıdaki jüri tarafından oybirliği / oyçokluğu ile kabul edilmiştir.

.....	.....	.....
Jüri Başkanı	**Üye**	**Üye**

ÖNSÖZ

Yapay zeka teknolojilerinin gündelik hayatın her alanına hızla nüfuz ettiği günümüzde, dil bariyerlerinin ortadan kaldırılması ve bilgiye erişimin demokratikleştirilmesi giderek daha büyük bir önem kazanmaktadır. Video içeriklerinin küresel ölçekte üretilip tüketildiği dijital çağda, bir içeriğin yalnızca üretildiği dili konuşan kitlelere ulaşması ciddi bir erişim eşitsizliği yaratmaktadır. Bu çalışma, söz konusu eşitsizliği yapay zeka teknolojileriyle gidermeyi amaçlayan bir girişimin ürünüdür.

Proje fikrinin şekillenme sürecinde NeviTech bünyesinde yürütülen staj çalışmaları belirleyici bir rol oynamıştır. Farklı yapay zeka modellerinin gerçek dünya problemlerine uygulanmasına yönelik pratik deneyim, bu çalışmanın hem kapsam hem de yöntem açısından olgunlaşmasına önemli katkı sağlamıştır.

Bu çalışmanın ortaya çıkmasında emeği geçen herkese en içten teşekkürlerimi sunmak istiyorum. Akademik danışmanım Dr. Öğretim Üyesi Ulaş YURTSEVER'e, çalışma süresince gösterdiği yönlendirici katkılar, yapıcı eleştiriler ve sabırlı rehberlik için derin şükranlarımı sunarım. Staj sürecimde değerli deneyimlerini ve teknik birikimini benimle paylaşan NeviTech ekibine teşekkür ederim.

Sakarya Üniversitesi Bilgisayar Mühendisliği programındaki dört yıllık eğitim sürecim boyunca birlikte çalıştığım, aynı derslerde kafa yorduğum ve aynı evi paylaştığım sınıf arkadaşlarım Duygu, Ayşe, Emine, Seher ve Leyla'ya aynı eve paylaşmasak da her zaman yanımda olan Rüveyda'ya akademik zorlukların yanı sıra hayatın her alanında gösterdikleri destek ve dostluk için özellikle teşekkür etmek istiyorum. Bu süreçte her zaman yanımda olan aileme ise minnettarlığımı kelimelerle ifade etmek güçtür.

Azra Nur TEKBAŞ
Sakarya, 2026

İÇİNDEKİLER

ÖNSÖZ **iii**

İÇİNDEKİLER **iv**

SİMGELER VE KISALTMALAR LİSTESİ **vii**

ŞEKİLLER LİSTESİ **ix**

TABLOLAR LİSTESİ **x**

ÖZET **xi**

1 GİRİŞ **1**

1.1 Proje Uygulama Takvimi 2

1.2 Projenin Maliyet Analizi 3

1.3 Projenin Amacı ve Kapsamı 4

1.4 Problemin Tanımı 5

1.5 Çalışmanın Önemi 6

1.6 Çalışmanın Kapsamı ve Sınırlamaları 6

2 TEORİK ALTYAPI VE SİSTEM MİMARİSİ **8**

2.1 Konuşma Tanıma ve Ses İşleme 8

2.1.1 Transformer mimarisi ve dikkat mekanizması 8

2.1.2 WhisperX modeli ve zorunlu hizalama 9

2.2 Makine Çevirisi 9

2.2.1 Sinir ağı tabanlı çeviri sistemleri 9

2.2.2 DeepL ve bağlamsal çeviri yaklaşımı 10

2.3 Yapay Zeka Tabanlı Ses Sentezi 10

2.3.1 Derin öğrenme ile ses üretimi 10

2.3.2 ElevenLabs çok dilli ses sentezi ve ses klonlama 10

2.4 Yüz Hareketi Senkronizasyonu 11

2.4.1 Wav2Lip mimarisi ve SyncNet 11

2.5 Genel Sistem Mimarisi 11

2.6 Kullanılan Teknolojiler ve Araçlar 13
3 UYGULAMA MİMARİSİ VE BULGULAR 16
3.1 Dublaj Modülü 16
3.1.1 Ses indirme ve ön işleme 16
3.1.2 Konuşma tanıma ve zaman damgalama 17
3.1.3 Segment bazlı çeviri 17
3.1.4 Ses sentezi ve klonlama 17
3.1.5 Ses-video senkronizasyonu 18
3.2 Altyazı ve Transkripsiyon Modülü 18
3.2.1 Çoklu giriş desteği 18
3.2.2 Akıllı parçalama mekanizması 19
3.2.3 Dışa aktarım formatları 21
3.3 Yüz Hareketi Senkronizasyonu Modülü 21
3.3.1 Medya hazırlama ve ses dönüşümü 22
3.3.2 Wav2Lip çıkarım süreci 22
3.4 Yazılım Mimarisi 23
3.4.1 Arka uç servisi — FastAPI 23
3.4.2 Ön yüz — web arayüzü 24
3.4.3 Sistem izleme ve performans takibi 26
3.5 Deneysel Bulgular ve Sistem Performansı 27
3.5.1 Dublaj modülü performansı 27
3.5.2 Altyazı modülü performansı 28
3.5.3 Genel değerlendirme 28
4 DEĞİŞİKLİK YÖNETİMİ VE MÜHENDİSLİK STANDARTLARI 29
4.1 Sürüm Denetim Sistemi ve Geliştirme Süreci 29
4.2 Modüler Mimari ve Bakım Kolaylığı 30
4.3 Test Yöntemleri ve Kalite Güvencesi 30
4.4 Sistem Genişletilebilirliği ve Ölçeklenebilirlik 32
5 TİCARİLEŞME PLANI 34

5.1 Pazar Analizi ve Hedef Kitle 34
5.2 İş Modeli ve Gelir Stratejisi 35
5.2.1 Fiyatlandırma katmanları 35
5.2.2 Maliyet yapısı ve kâr marjı 36
5.3 Rekabet Analizi 36
5.4 Büyüme Yol Haritası 37
6 VERİ VE ALTYAPI GÜVENLİĞİ DEĞERLENDİRMESİ 39
6.1 API Güvenliği ve Anahtar Yönetimi 39
6.2 Dosya Yükleme Güvenliği ve Girdi Denetimi 40
6.3 Üçüncü Taraf Hizmet Güvenliği 40
6.4 Genel Güvenlik Değerlendirmesi 41
7 SONUÇ VE ÖNERİLER 43
7.1 Sonuçlar 43
7.2 Öneriler ve Gelecek Çalışmalar 44
KAYNAKLAR 46
EKLER 48
ÖZGEÇMİŞ 51
DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI 52

SİMGELER VE KISALTMALAR LİSTESİ

d_k	:	Transformer dikkat mekanizmasında anahtar vektörünün boyutu
Q	:	Transformer dikkat mekanizmasında sorgu matrisi (Query)
K	:	Transformer dikkat mekanizmasında anahtar matrisi (Key)
V	:	Transformer dikkat mekanizmasında değer matrisi (Value)
T	:	Matris devriği (Transpose)
AI	:	Yapay Zeka (Artificial Intelligence)
API	:	Uygulama Programlama Arayüzü (Application Programming Interface)
ASR	:	Otomatik Konuşma Tanıma (Automatic Speech Recognition)
CORS	:	Kaynaklar Arası Kaynak Paylaşımı (Cross-Origin Resource Sharing)
CPU	:	Merkezi İşlemci Birimi (Central Processing Unit)
FLAC	:	Kayıpsız Ses Sıkıştırma Kodeci (Free Lossless Audio Codec)
GAN	:	Üretken Çekişmeli Ağ (Generative Adversarial Network)
GPU	:	Grafik İşlemci Birimi (Graphics Processing Unit)
HTTP	:	Hiper Metin Transfer Protokolü (Hypertext Transfer Protocol)
HTTPS	:	Güvenli Hiper Metin Transfer Protokolü (Hypertext Transfer Protocol Secure)
JSON	:	JavaScript Nesne Gösterimi (JavaScript Object Notation)
JWT	:	JSON Web Jetonu (JSON Web Token)
KOBİ	:	Küçük ve Orta Büyüklükteki İşletme
LSTM	:	Uzun Kısa Süreli Bellek (Long Short-Term Memory)
MIME	:	Çok Amaçlı İnternet Posta Uzantıları (Multipurpose Internet Mail Extensions)
MP3	:	MPEG Ses Katmanı 3 (MPEG Audio Layer 3)
MP4	:	MPEG-4 Video Kapsayıcı Formatı (MPEG-4 Part 14)
MRR	:	Aylık Yinelenen Gelir (Monthly Recurring Revenue)
NLP	:	Doğal Dil İşleme (Natural Language Processing)
PCM	:	Darbe Kod Modülasyonu (Pulse-Code Modulation)
REST	:	Temsili Durum Transferi (Representational State Transfer)
RNN	:	Tekrarlayan Sinir Ağı (Recurrent Neural Network)
SaaS	:	Hizmet Olarak Yazılım (Software as a Service)
SLA	:	Hizmet Düzeyi Anlaşması (Service Level Agreement)

SRT	:	SubRip Altyazı Formatı (SubRip Text)
SSL	:	Güvenli Yuva Katmanı (Secure Sockets Layer)
TLS	:	Taşıma Katmanı Güvenliği (Transport Layer Security)
TTS	:	Metinden Konuşmaya (Text-to-Speech)
URL	:	Tekdüzen Kaynak Bulucu (Uniform Resource Locator)
UUID	:	Evrensel Benzersiz Tanımlayıcı (Universally Unique Identifier)
VRAM	:	Video Rastgele Erişim Belleği (Video Random Access Memory)
VTT	:	Web Video Metin Parçaları (Web Video Text Tracks)
WAV	:	Dalga Formu Ses Dosyası (Waveform Audio File Format)

ŞEKİLLER LİSTESİ

Şekil 1.1. Proje uygulama takvimi Gantt şeması 4

Şekil 2.1. Sistemin genel mimarisi ve modüller arası ilişkiler 13

Şekil 3.1. Dublaj modülü boru hattı akış diyagramı 16
Şekil 3.2. Altyazı modülü akıllı parçalama mekanizması akış diyagramı . . . 20
Şekil 3.3. Yüz hareketi senkronizasyonu modülü arayüzü 22
Şekil 3.4. FastAPI Swagger UI arayüzü ve API uç noktaları 24
Şekil 3.5. Web arayüzü dublaj sekmesi başlangıç durumu 25
Şekil 3.6. Web arayüzü işlem devam ederken ilerleme paneli 25
Şekil 3.7. Web arayüzü işlem tamamlandığında sonuç ve monitor paneli . . . 26

Şekil 7.1. Dublaj modülü tam ekran görüntüsü 48
Şekil 7.2. Altyazı ve transkripsiyon modülü tam ekran görüntüsü 49
Şekil 7.3. Lip sync modülü tam ekran görüntüsü 50

TABLOLAR LİSTESİ

Tablo 1.1. Proje uygulama takvimi 3
Tablo 1.2. Tahmini proje maliyet tablosu (4 aylık geliştirme süreci) 4

Tablo 2.1. Kullanılan teknolojiler ve rolleri 15

Tablo 3.1. Dublaj modülü performans ölçümleri (A100 GPU) 27
Tablo 3.2. Altyazı modülü performans ölçümleri ve parçalama davranışı . . . 28

Tablo 4.1. Test senaryoları ve sonuçları 31
Tablo 4.2. Genişletme senaryoları ve gerekli değişiklikler 33

Tablo 5.1. Önerilen abonelik planları 35
Tablo 5.2. Rekabet karşılaştırma matrisi 37
Tablo 5.3. Ticarileşme yol haritası 38

Tablo 6.1. Güvenlik değerlendirme özeti 42

ÖZET

Bu çalışmada, video içeriklerinin farklı dillere otomatik olarak aktarılmasını sağlayan, boru hattı mimarisine dayalı çok modüllü bir web uygulaması geliştirilmiştir. Uygulama; otomatik dublaj ve altyazı oluşturma olmak üzere iki temel modülden oluşmakta, bunlara ek olarak Wav2Lip derin öğrenme modeli tabanlı yüz hareketi senkronizasyonu özelliği prototip düzeyinde sisteme dahil edilmiştir.

Dublaj modülünde,YouTube platformundanindirilen ses dosyası sırasıyla konuşma tanıma, makine çevirisi ve ses sentezi aşamalarından geçirilmiştir. Konuşma tanıma aşamasında whisperX modeli kullanılmış ve her konuşma kesimine sözcük düzeyinde milisaniye hassasiyetinde zaman damgası atanmıştır. Çeviri aşamasında DeepL arayüzü kullanılmış, segment bazlı işleme yaklaşımıyla zaman damgaları değiştirilmeksizin yalnızca metin içeriği hedef dile aktarılmıştır. Ses sentezi aşamasında ElevenLabs tercih edilmiş; ses klonlama özelliği sayesinde orijinal konuşmacının ses karakteri korunarak hedef dilde seslendirme gerçekleştirilmiştir. Son aşamada FFmpeg aracıyla üretilen ses kesimleri zaman damgalarına hizalanarak özgün video üzerine yerleştirilmiş ve orijinal ses kanalı arka planda zayıflatılmıştır.

Altyazı ve transkripsiyon modülünde hem YouTube bağlantısı hem de yerel video ve ses dosyası girişi desteklenmiştir. Otuz dakikayı aşan içerikler için akıllı parçalama mekanizması uygulanmış; içerikler on dakikalık bölümlere ayrılarak her bölüm whisperX ile bağımsız biçimde işlenmiş, bölümler arası bağlam sürekliliğini korumak amacıyla üç saniyelik örtüşme payı bırakılmış ve zaman damgaları birleştirilerek bütüncül bir transkripsiyon elde edilmiştir. Üretilen çıktılar istenilen formatlarda dışa aktarılabilmektedir. Prototip olarak sisteme eklenen yüz hareketi senkronizasyonu modülünde ise yüz tespiti ve Wav2Lip UNet mimarisi kullanılarak verilen ses dosyasına göre görüntü veya video üzerindeki dudak hareketleri yeniden oluşturulmuştur.

Uygulama, FastAPI tabanlı asenkron arka uç servisi ve tek sayfalı web arayüzünden oluşan istemci-sunucu mimarisine dayanmaktadır.Tüm modüllerde işlem süresi ve bellek kullanımı aşama bazında izlenmiş; her işlem tamamlandığında gerçek zamanlı performans raporu kullanıcıya sunulmuştur.

Anahtar kelimeler: Otomatik Dublaj, Konuşma Tanıma, Makine Çevirisi, Ses Sentezi, Altyazı Üretimi, Zaman Damgası Hizalama, Wav2Lip, Derin Öğrenme, Web Tabanlı Uygulama

BÖLÜM 1. GİRİŞ

Dijital içerik tüketiminin hızla küreselleştiği günümüzde, farklı dillerde üretilen video içeriklerine erişim ihtiyacı her geçen gün artmaktadır. YouTube başta olmak üzere çeşitli çevrimiçi platformlarda yayımlanan içeriklerin büyük çoğunluğu İngilizce veya diğer dünya dillerinde üretilmekte; bu durum, hedef kitlesi farklı bir dil konuşan izleyiciler için ciddi bir erişim engeli oluşturmaktadır. Geleneksel altyazı yöntemi bu engeli kısmen aşmakla birlikte, izleme deneyimini olumsuz etkilemekte ve görme engelli bireyler ile dikkatini ekrana yöneltme güçlüğü çeken kullanıcılar için yetersiz kalmaktadır. Dublaj ise bu sorunun en etkili çözümü olarak öne çıkmaktadır; zira hedef dilde gerçekleştirilen seslendirme, izleyicinin içeriği anadilinde takip etmesine olanak tanımaktadır [**nakamura2018**].

Bununla birlikte, geleneksel dublaj süreci ciddi maliyet ve zaman yükü barındırmaktadır. Profesyonel bir dublaj prodüksiyonu; çeviri uzmanları, seslendirme sanatçıları, ses kayıt stüdyoları ve ses mühendislerini bir araya getiren karmaşık bir iş akışını gerektirmekte; bu durum hem büyük yapım şirketleri hem de bireysel içerik üreticileri için önemli bir kısıt oluşturmaktadır. Özellikle bağımsız içerik üreticileri ve küçük ölçekli medya kuruluşları, bu maliyeti karşılayamamaları nedeniyle içeriklerini geniş bir uluslararası kitleye taşıyamamaktadır [**toral2018**].

Yapay zeka alanındaki son gelişmeler, bu sürecin otomatikleştirilmesini mümkün kılmaktadır. Konuşma tanıma, makine çevirisi ve ses sentezi teknolojilerindeki hızlı ilerleme; geleneksel dublaj sürecinin birden fazla uzman gerektiren aşamalarının yazılım sistemleri tarafından üstlenilmesine olanak sağlamaktadır [**radford2023**]. Bu çalışmada, söz konusu teknolojileri boru hattı mimarisi içinde bir araya getirerek video içeriklerinin istenilen bir hedef dile otomatik olarak dublajlanmasını, transkribe edilmesini ve altyazıya dönüştürülmesini sağlayan çok modüllü bir web uygulaması tasarlanmış ve geliştirilmiştir.

Raporun ilerleyen bölümleri şu biçimde düzenlenmiştir: İkinci bölümde teorik altyapı, kullanılan modeller ve sistem mimarisi ele alınmaktadır. Üçüncü bölümde uygulama mimarisi ve deneysel bulgular sunulmaktadır. Dördüncü bölümde değişiklik yönetimi ve mühendislik standartları incelenmekte, beşinci bölümde ticarileşme planı ortaya konmaktadır. Altıncı bölümde güvenlik değerlendirmesi yapılmakta, yedinci ve son bölümde ise sonuçlar ve öneriler paylaşılmaktadır.

1.1. Proje Uygulama Takvimi

Proje, çok modüllü bir video yerelleştirme sisteminin tasarlanması, geliştirilmesi ve test edilmesi olmak üzere iki ana fazda yürütülmektedir. Birinci faz; temel işlem bileşenlerinin bağımsız modüller olarak geliştirilmesini ve ardından uçtan uca entegrasyonun sağlanmasını kapsamaktadır. İkinci fazda ise sistemin web arayüzü üzerinden son kullanıcıya sunulması, performans optimizasyonları ve genişletme çalışmaları planlanmaktadır.

Tablo 1.1'de detaylandırılan iş paketleri, projenin 16 haftalık geliştirme sürecini özetlemektedir. Ekim ayında literatür taraması ve gereksinim analizi ile başlayan süreç; Kasım ayında temel işlem modüllerinin geliştirilmesiyle devam etmiş, Aralık ve Ocak aylarında web arayüzü entegrasyonu, sistem testleri ve raporlama çalışmalarıyla tamamlanmıştır.

Tablo 1.1. Proje uygulama takvimi

Kod	İş Paketi	Kapsam / Çıktı	Süre (Hafta)	Başlangıç – Bitiş	Bağımlılık
İP1	Literatür taraması ve gereksinim analizi	Alan incelemesi, araç ve platform seçimi	2	H1 – H2	—
İP2	Ses indirme modülü	yt-dlp ile WAV formatında ses indirme	1	H3	İP1
İP3	Konuşma tanıma modülü	whisperX ile zaman damgalı transkripsiyon	2	H4 – H5	İP2
İP4	Çeviri modülü	DeepL arayüzü ile segment bazlı çeviri	1	H6	İP3
İP5	Ses sentezi modülü	ElevenLabs arayüzü ile seslendirme ve klonlama	2	H7 – H8	İP4
İP6	Ses-video birleştirme modülü	FFmpeg ile senkronizasyon	2	H9 – H10	İP5
İP7	Altyazı modülü	Akıllı parçalama, çoklu format dışa aktarım	2	H11 – H12	İP3
İP8	Web arayüzü	FastAPI arka uç, tek sayfalı ön yüz	2	H11 – H12	İP6
İP9	Entegrasyon ve test	Uçtan uca boru hattı testi	2	H13 – H14	İP7, İP8
İP10	Raporlama ve sunum	Bitirme raporu ve sözlü sınav materyalleri	2	H15 – H16	İP9

1.2. Projenin Maliyet Analizi

Geliştirilen sistemin ekonomik sürdürülebilirliğini değerlendirmek amacıyla kapsamlı bir maliyet analizi gerçekleştirilmiştir. Sistem, büyük ölçüde açık kaynaklı araçlara ve kullandıkça öde modeliyle çalışan bulut tabanlı arayüzlere dayandığından, donanım satın alımı gerektiren geleneksel yazılım projelerinden farklı bir maliyet yapısı sergilemektedir.

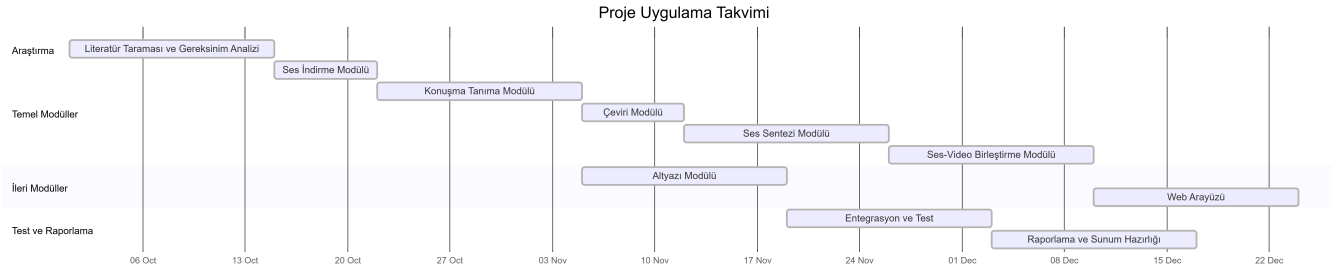
Maliyet kalemleri üç ana kategoride ele alınmıştır. Birincisi, konuşma tanıma aşamasının yerel olarak çalıştırılabilmesi için gereken hesaplama altyapısıdır. İkincisi, çeviri ve seslendirme aşamalarında kullanılan ticari arayüzlerin lisans ve kullanım ücretleridir. Üçüncüsü ise projenin tasarımı, kodlanması ve test edilmesinde harcanan

mühendislik iş gücüdür.

Tablo 1.2. Tahmini proje maliyet tablosu (4 aylık geliştirme süreci)

Gider Kalemi	Açıklama	Birim Fiyat	Miktar	Toplam Tutar
ElevenLabs Starter	Ses sentezi ve klonlama arayüzü	215 TL/ay	4 Ay	860 TL
DeepL Free API	Çeviri arayüzü (500.000 karakter/ay)	Ücretsiz	4 Ay	0 TL
Google Colab Pro	GPU hesaplama (whisperX için)	360 TL/ay	4 Ay	1.440 TL
GitHub Copilot	Yapay zeka kod asistanı lisansı	360 TL/ay	4 Ay	1.440 TL
Mühendislik eforu	Yazılım geliştirme ve Ar-Ge	15.000 TL/ay	4 Ay	60.000 TL
			Genel Toplam	**63.740 TL**

Tablo 1.2'de görüldüğü üzere sistemin doğrudan yazılım ve altyapı maliyeti oldukça düşüktür. ElevenLabs'ın aylık 6 dolarlık başlangıç planı aylık 10.000 karakter seslendirme kapasitesi sunmakta; bu kapasite geliştirme ve test aşamaları için yeterli olmaktadır. DeepL arayüzünün ücretsiz katmanı aylık 500.000 karakter çeviri imkânı sağlamaktadır. Bu maliyet yapısı, sistemin yalnızca bireysel geliştiriciler için değil, küçük içerik prodüksiyon ekipleri için de erişilebilir olduğunu ortaya koymaktadır.



Şekil 1.1. Proje uygulama takvimi Gantt şeması

1.3. Projenin Amacı ve Kapsamı

Bu projenin temel amacı, video içeriklerinin farklı dillere otomatik olarak aktarılmasını sağlayan, yapay zeka teknolojilerine dayalı, modüler ve düşük maliyetli bir web

uygulaması geliştirmektir. Sistem; sesi indirmekten senkronize dublajlı videoyu oluşturmaya, ham sesi altyazıya dönüştürmekten farklı formatlarda dışa aktarmaya kadar olan tüm süreci insan müdahalesi gerektirmeksizin yürütebilecek biçimde tasarlanmıştır.

Projenin teknik kapsamı beş temel bileşenden oluşmaktadır. **Ses indirme ve ön işleme** bileşeninde yt-dlp aracı kullanılarak YouTube URL'inden yüksek kaliteli ses dosyasının WAV formatında yerel sisteme indirilmesi ve FFmpeg aracıyla işleme hazır hale getirilmesi hedeflenmiştir. **Konuşma tanıma** bileşeninde whisperX large-v2 modeliyle sesin metne dönüştürülmesi ve her konuşma kesimine sözcük düzeyinde zaman damgası atanması sağlanmıştır. **Makine çevirisi** bileşeninde zaman damgalı metin kesimlerinin DeepL arayüzü aracılığıyla hedef dile aktarılması, çeviri sürecinde zaman damgalarının korunması gerçekleştirilmiştir. **Yapay zeka tabanlı ses sentezi** bileşeninde çevrilen metin kesimlerinin ElevenLabs eleven_multilingual_v2 modeli ile seslendirilmesi ve ses klonlama özelliğiyle orijinal konuşmacının ses karakterinin korunması amaçlanmıştır. **Ses-video senkronizasyonu ve altyazı üretimi** bileşeninde ise FFmpeg aracıyla seslendirme dosyalarının zaman damgalarına hizalanarak video ile birleştirilmesi ve SRT, VTT, JSON ile düz metin formatlarında altyazı çıktısının üretilmesi sağlanmıştır.

1.4. Problemin Tanımı

Otomatik video yerelleştirme, birden fazla yapay zeka alt alanının kesiştiği ve her birinin kendine özgü güçlükler barındırdığı karmaşık bir problemdir [**li2019**].

Zaman damgası tutarlılığı, sistemin çözüm üretmesi gereken temel sorunların başında gelmektedir. Konuşma tanıma aşamasında elde edilen zaman damgaları, çeviri ve seslendirme aşamalarından geçerken bozulmamalıdır. Segment sınırlarının korunması, üretilen dublajın video ile senkronize olabilmesinin ön koşuludur.

Ses süresi uyumsuzluğu da kritik bir güçlük oluşturmaktadır. Aynı anlamı taşıyan bir cümle, farklı dillerde farklı sürelerde seslendirilmektedir. Bu uyumsuzluk yönetilmediğinde senkronizasyon bozulmakta ve doğal olmayan bir izleme deneyimi ortaya çıkmaktadır.

Ses kalitesi ve doğallık açısından geleneksel metin-okuma sistemleri, mekanik ve yapay ses kalitesiyle kullanıcı deneyimini olumsuz etkilemektedir. Orijinal konuşmacının vurgu, ton ve ritim örüntülerini hedef dildeki seslendirmede yansıtabilmek kritik öneme sahiptir.

Uzun içerik işleme, otuz dakikayı aşan içeriklerin tek seferde işlenmesinin hem bellek sorunlarına hem de zaman damgası kayıplarına yol açması nedeniyle akıllı parçalama mekanizmalarının geliştirilmesini zorunlu kılmaktadır.

Modüler entegrasyon karmaşıklığı ise birbirinden bağımsız araçların tutarlı ve hatasız biçimde bir araya getirilmesini, her aracın farklı veri formatları ve hata yönetimi mekanizmaları barındırması nedeniyle önemli bir mühendislik güçlüğü olarak öne çıkarmaktadır.

1.5. Çalışmanın Önemi

Bu çalışma, endüstriyel ve akademik açıdan birkaç temel katkı sunmaktadır.

Erişilebilirlik katkısı bakımından yüksek kaliteli dublaj ve altyazı hizmetlerine erişim, büyük prodüksiyon bütçelerine sahip kurumlarla sınırlı kalmaktaydı. Geliştirilen sistem, bu hizmetin bireysel içerik üreticileri ve küçük yapım ekipleri tarafından da kullanılabilir hale gelmesine katkı sağlamaktadır.

Teknolojik entegrasyon değeri açısından konuşma tanıma, makine çevirisi ve ses sentezi alanlarındaki güncel teknolojilerin bütünleşik bir boru hattı içinde bir araya getirilmesi, bu üç alanın birlikte nasıl çalışabileceğine dair somut bir uygulama örneği sunmaktadır [**baevski2020**].

Ekonomik verimlilik bağlamında geleneksel dublaj maliyetlerinin büyük bölümünü oluşturan insan iş gücünün otomasyonla ikame edilmesi, içerik yerelleştirme sürecinde ciddi maliyet ve zaman tasarrufu sağlamaktadır.

Ölçeklenebilirlik açısından modüler mimari sayesinde sistem, farklı dil çiftleri ve farklı içerik türleri için kolaylıkla yapılandırılabilmektedir. Herhangi bir bileşen, daha üstün bir alternatif geliştirildiğinde sistemin geri kalanını etkilemeksizin değiştirilebilmektedir.

1.6. Çalışmanın Kapsamı ve Sınırlamaları

Bu çalışma, tek konuşmacılı video içeriklerine yönelik otomatik dublaj ve altyazı boru hattının tasarımı ile uygulanmasını kapsamaktadır. Ses indirme, konuşma tanıma, segment bazlı çeviri, yapay zeka seslendirme, ses-video birleştirme ve altyazı üretimi modüllerinin tamamı çalışır durumda geliştirilmiş ve uçtan uca entegrasyon sağlanmıştır. Wav2Lip tabanlı yüz hareketi senkronizasyonu modülü prototip düzeyinde

sisteme dahil edilmiştir.

Çalışmanın mevcut sınırlamaları şu biçimde özetlenebilir: Sistem yalnızca tek konuşmacılı içerikler için optimize edilmiş olup birden fazla konuşmacı içeren videolarda konuşmacı ayırt etme mekanizması henüz uygulanmamıştır. Seslendirme aşamasında üretilen ses segmentlerinin süresi orijinal segmentin süresini aştığında uygulanan hız uyarlama mekanizması temel düzeyde çalışmaktadır. Gerçek zamanlı işleme hedeflenmemiş olup sistem çevrimdışı toplu işleme mantığıyla çalışmaktadır. ElevenLabs başlangıç planının aylık karakter kotası, uzun içeriklerin tam seslendirmesinde kısıt oluşturabilmektedir.

BÖLÜM 2. TEORİK ALTYAPI VE SİSTEM MİMARİSİ

Bu bölümde, geliştirilen sistemin temelini oluşturan konuşma tanıma, makine çevirisi, ses sentezi ve yüz hareketi senkronizasyonu alanlarına ilişkin teorik altyapı ele alınmakta; sistemin genel mimarisi ve kullanılan teknolojiler teknik gerekçeleriyle birlikte açıklanmaktadır.

2.1. Konuşma Tanıma ve Ses İşleme

Konuşma tanıma, ham ses sinyalinin işlenerek anlamlı metne dönüştürülmesi sürecidir. Bu süreç; akustik modelleme, dil modelleme ve kod çözme olmak üzere üç temel bileşenden oluşmaktadır. Geleneksel konuşma tanıma sistemleri, gizli Markov modelleri ve Gauss karışım modelleri gibi istatistiksel yaklaşımlara dayanmaktaydı. Ancak derin öğrenme alanındaki gelişmeler, bu sistemlerin yerini uçtan uca sinir ağı mimarilerine bırakmasını sağlamıştır [**graves2013**].

2.1.1. Transformer mimarisi ve dikkat mekanizması

Vaswani ve arkadaşları tarafından 2017 yılında önerilen Transformer mimarisi, doğal dil işleme ve ses işleme alanlarında köklü bir dönüşüm yaratmıştır [**vaswani2017**]. Önceki tekrarlayan sinir ağı mimarilerinin aksine Transformer, veriyi sıralı işlemek yerine **öz-dikkat** (self-attention) mekanizmasını kullanmaktadır. Bu mekanizma, bir dizideki her elemanın diğer tüm elemanlarla olan ilişkisini eş zamanlı olarak hesaplayarak bağlamsal ağırlıkları belirlemektedir. Söz konusu yaklaşım, uzun mesafeli bağımlılıkların modellenmesinde tekrarlayan mimarilere kıyasla belirgin biçimde üstün performans sergilemektedir.

Öz-dikkat mekanizması, sorgu (Q), anahtar (K) ve değer (V) matrislerinden oluşan üç doğrusal dönüşüm üzerine inşa edilmektedir. Dikkat ağırlıkları Denklem 2.1'de verildiği biçimde hesaplanmaktadır.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.1}$$

Bu denklemde d_k, anahtar vektörünün boyutunu ifade etmekte olup ölçekleme çarpanı

olarak kullanılmaktadır. Ölçekleme işlemi, yüksek boyutlu uzaylarda iç çarpımların büyük değerler almasından kaynaklanan gradyan sorunlarını engellemektedir.

2.1.2. WhisperX modeli ve zorunlu hizalama

OpenAI tarafından 2022 yılında kamuoyuyla paylaşılan **Whisper**, 680.000 saatlik çok dilli ses verisiyle eğitilmiş büyük ölçekli bir konuşma tanıma modelidir [**radford2023**]. Kodlayıcı-çözücü Transformer mimarisini temel alan model; konuşma tanıma, dil tespiti, zaman damgası oluşturma ve çeviri görevlerini tek bir mimari çatı altında gerçekleştirebilmektedir. Whisper, tiny, base, small, medium ve large olmak üzere beş farklı ölçekte sunulmaktadır. Bu çalışmada en yüksek tanıma doğruluğunu sunan large-v2 modeli tercih edilmiştir.

Orijinal Whisper modeli cümle düzeyinde zaman damgası üretebilmekte; ancak sözcük düzeyinde hizalama yapamamaktadır. Bu çalışmada kullanılan **whisperX**, wav2vec2 gibi zorunlu hizalama modelleri aracılığıyla sözcük düzeyinde milisaniye hassasiyetinde zaman damgaları üretmektedir [**bain2022**]. Bu özellik, ses-video senkronizasyonunun doğruluğu açısından kritik öneme sahiptir. Bunun yanı sıra whisperX, toplu işleme desteği sayesinde orijinal Whisper'a kıyasla belirgin biçimde daha hızlı çıkarım gerçekleştirebilmektedir.

2.2. Makine Çevirisi

Makine çevirisi, bir dildeki metni insan müdahalesi olmaksızın başka bir dile otomatik olarak aktarma sürecidir. İstatistiksel makine çevirisi döneminden günümüze, sinir ağı tabanlı yaklaşımlar bu alanda baskın yöntem hâline gelmiştir [**bahdanau2015**].

2.2.1. Sinir ağı tabanlı çeviri sistemleri

Sinir ağı tabanlı makine çevirisi, kaynak dildeki cümleyi vektör uzayında temsil eden bir kodlayıcı ve bu temsili hedef dildeki cümleye dönüştüren bir çözücüden oluşmaktadır. Transformer mimarisinin bu alana uyarlanmasıyla birlikte çeviri kalitesi önemli ölçüde artmış; özellikle uzun ve karmaşık cümlelerde bağlamsal tutarlılık belirgin biçimde iyileşmiştir. Günümüzde ticari çeviri sistemlerinin büyük çoğunluğu Transformer tabanlı mimarilere dayanmaktadır.

2.2.2. DeepL ve bağlamsal çeviri yaklaşımı

DeepL, Köln merkezli DeepL SE şirketi tarafından 2017 yılında piyasaya sürülmüş yapay zeka tabanlı bir makine çeviri hizmetidir. Transformer mimarisine dayalı sinir ağı modelleri kullanan DeepL, özellikle Avrupa dilleri arasındaki çevirilerde rakiplerine kıyasla daha doğal ve akıcı çıktılar ürettiği bağımsız değerlendirmelerde tutarlı biçimde ortaya konmaktadır [**laubli2018**]. DeepL'in üstünlüğünün başlıca kaynağı bağlamsal anlama konusundaki başarısıdır; model yalnızca bireysel cümleleri değil, paragraf düzeyinde bağlamı da işleyerek terminoloji ve ton sürekliliği sağlamaktadır. Bu çalışmada DeepL ücretsiz arayüzü kullanılmıştır. Aylık 500.000 karakterlik çeviri kapasitesi sunan bu plan, geliştirme ve test aşamaları için yeterlidir.

2.3. Yapay Zeka Tabanlı Ses Sentezi

Ses sentezi, metinden insan sesine benzer konuşma üretme sürecidir. Kural tabanlı ve istatistiksel yaklaşımların hâkim olduğu ilk kuşak sistemlerin yerini, günümüzde derin öğrenme tabanlı uçtan uca modeller almıştır [**oord2016**].

2.3.1. Derin öğrenme ile ses üretimi

Modern ses sentezi sistemleri, metni önce akustik özellik dizisine dönüştüren bir akustik model ile bu özellik dizisini ham ses dalgasına çeviren bir vooder bileşeninden oluşmaktadır. WaveNet, Tacotron ve FastSpeech gibi öncü modeller bu alanda referans mimari olarak kabul görmektedir [**shen2018**]. **Ses klonlama** ise sınırlı miktarda örnek ses verisi kullanılarak belirli bir konuşmacının ses karakterini öğrenen ve bu karakteri yeni metinleri seslendiririrken yeniden üreten bir yaklaşımdır. Yalnızca birkaç dakika uzunluğundaki örnek ses, günümüz modellerinin konuşmacıya özgü bir ses profili oluşturması için yeterli olmaktadır.

2.3.2. ElevenLabs çok dilli ses sentezi ve ses klonlama

ElevenLabs, 2022 yılında Piotr Dabkowski ve Mati Staniszewski tarafından kurulan ve yapay zeka tabanlı ses sentezi ile ses klonlama alanında öne çıkan bir teknoloji şirketidir. Bu çalışmada kullanılan **eleven_multilingual_v2** modeli, 29 dili destekleyen ve bu diller arasında ses karakteri aktarımı yapabilen bir sinir ağı mimarisine dayanmaktadır

[**elevenlabs2023**]. Model, girilen metni işlerken yalnızca fonetik yapıyı değil; cümle ritmini, konuşma hızını ve duygusal tonu da modellemekte; bu sayede hedef dildeki çıktı orijinal konuşmacının söyleyiş tarzına yakın bir nitelik kazanmaktadır. Anlık ses klonlama özelliği ise yalnızca birkaç dakika uzunluğundaki örnek sesi analiz ederek konuşmacıya özgü bir ses profili oluşturmakta ve bu profil hedef dildeki seslendirme sırasında kullanılmaktadır.

2.4. Yüz Hareketi Senkronizasyonu

Yüz hareketi senkronizasyonu, verilen ses dosyasına uygun dudak hareketlerinin bir görüntü veya video üzerinde yapay olarak oluşturulması sürecidir. Bu alan, bilgisayarla görme ve derin öğrenmenin kesişim noktasında yer almaktadır [**prajwal2020**].

2.4.1. Wav2Lip mimarisi ve SyncNet

Wav2Lip, Prajwal ve arkadaşları tarafından 2020 yılında önerilen ve yüz hareketi senkronizasyonu alanında geniş kabul görmüş bir derin öğrenme modelidir [**prajwal2020**]. Model, bir üreteç ağ (UNet tabanlı) ile bir ayrımcı ağdan (**SyncNet**) oluşan koşullu üretken çekişmeli ağ mimarisine dayanmaktadır. Üreteç, ses ve video çerçevelerini girdi olarak alarak yeni dudak bölgesi üretmekte; SyncNet ise üretilen dudak hareketlerinin ses ile ne ölçüde senkronize olduğunu değerlendirmektedir. Yüz tespiti aşamasında **S3FD** modeli kullanılmakta; tespit edilen yüz bölgesi 96×96 piksel çözünürlüğe kırpılarak modele beslenmektedir. Bu çalışmada Wav2Lip, prototip düzeyinde sisteme dahil edilmiş olup wav2lip_gan ağırlıkları tercih edilmiştir.

2.5. Genel Sistem Mimarisi

Geliştirilen sistem, her işlem aşamasının bağımsız bir modül olarak tasarlandığı gevşek bağlı boru hattı mimarisine dayanmaktadır. Bu mimari yaklaşım; her bileşenin izole biçimde test edilmesine, hata ayıklamasının kolaylaşmasına ve herhangi bir bileşenin sistemin geri kalanını etkilemeksizin daha üstün bir alternatifle değiştirilmesine olanak tanımaktadır.

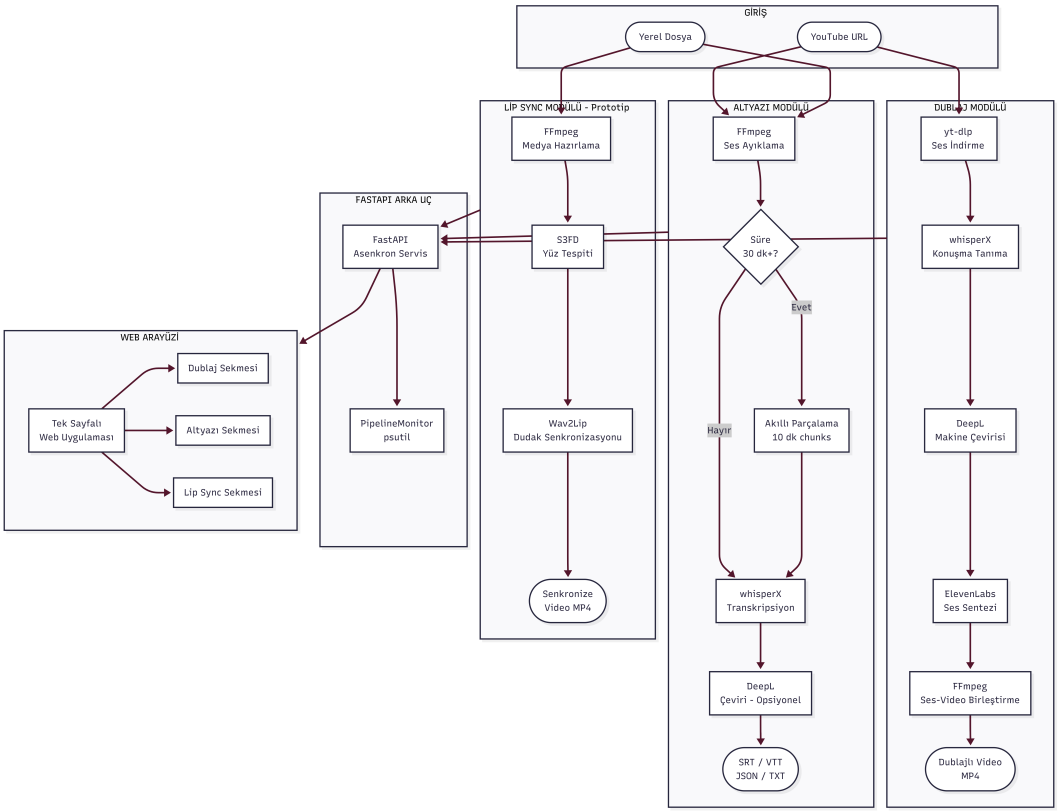
Sistem üç temel modülden oluşmaktadır: dublaj modülü, altyazı ve transkripsiyon modülü ile yüz hareketi senkronizasyonu modülü. Her modül, **FastAPI** tabanlı arka uç servisi üzerinden bağımsız uç noktalar aracılığıyla tetiklenmektedir.

Modüller arasındaki veri aktarımı JSON formatında gerçekleştirilmekte; kimlik doğrulama anahtarları ve yapılandırma parametreleri ortam değişkenleri aracılığıyla yönetilmektedir.

Dublaj modülünde veri akışı şu sırayı izlemektedir: YouTube URL'inden ses indirilmesi, whisperX ile zaman damgalı transkripsiyon üretilmesi, DeepL aracılığıyla segment bazlı çeviri yapılması, ElevenLabs ile her segment için ayrı ses dosyası üretilmesi ve FFmpeg ile ses dosyalarının orijinal video üzerine zaman damgasına göre yerleştirilmesi.

Altyazı ve transkripsiyon modülünde hem YouTube bağlantısı hem de yerel dosya girişi desteklenmektedir. Otuz dakikayı aşan içerikler için ses, on dakikalık parçalara bölünmekte; her parça bağımsız olarak işlenmekte ve zaman damgaları birleştirilerek bütüncül bir transkripsiyon elde edilmektedir. Bölümler arası bağlam sürekliliğini korumak amacıyla üç saniyelik örtüşme payı bırakılmaktadır.

Arka uç servisi, tüm uzun süreli işlemleri arka plan görevi olarak çalıştırmakta ve istemciye anında bir iş kimliği döndürmektedir. İstemci bu kimliği kullanarak durum sorgulama uç noktasını düzenli aralıklarla çağırmakta ve işlem tamamlandığında sonuç uç noktasından çıktıya erişmektedir. Sistem izleme bileşeni, her modülde işlem süresi ve bellek kullanımını aşama bazında kaydetmekte; bu veriler işlem tamamlandığında kullanıcıya performans raporu olarak sunulmaktadır.



Şekil 2.1. Sistemin genel mimarisi ve modüller arası ilişkiler

2.6. Kullanılan Teknolojiler ve Araçlar

Bu projede yüksek performanslı ses işleme, doğal dil anlama ve modern web standartlarına uygunluk hedeflenerek güncel bir teknoloji yığını tercih edilmiştir. Kullanılan araçlar ve tercih gerekçeleri aşağıda açıklanmaktadır.

Python (3.11), ses işleme modüllerinin, yapay zeka model entegrasyonlarının ve arka uç servisinin geliştirildiği ana programlama dilidir. Geniş kütüphane ekosistemi ve yapay zeka alanındaki yaygın kullanımı tercih gerekçesini oluşturmaktadır.

yt-dlp, YouTube ve 1.000'den fazla platformu destekleyen açık kaynaklı ses ve video indirme aracıdır. Daha önce yaygın biçimde kullanılan youtube-dl projesinin topluluk tarafından aktif olarak geliştirilen çatalı olup belirgin performans iyileştirmeleri ve genişletilmiş platform desteği sunmaktadır.

whisperX, OpenAI Whisper modelini temel alan ve zorunlu hizalama yöntemiyle sözcük düzeyinde zaman damgası üretebilen açık kaynaklı bir konuşma tanıma çerçevesidir. Toplu işleme desteği sayesinde orijinal Whisper'a kıyasla belirgin biçimde daha hızlı çıkarım gerçekleştirmektedir [**bain2022**].

DeepL API, bağlamsal çeviri kalitesiyle öne çıkan sinir ağı tabanlı makine çeviri hizmetidir. Ücretsiz katmanı aylık 500.000 karakter çeviri kapasitesi sunmaktadır.

ElevenLabs API, çok dilli ses sentezi ve ses klonlama hizmeti sunan yapay zeka platformudur. eleven_multilingual_v2 modeli 29 dili desteklemekte ve orijinal konuşmacının ses karakterini hedef dildeki seslendirmede koruyabilmektedir.

FFmpeg, ses ve video kaydı, dönüştürme ve akış işlemlerini kapsayan açık kaynaklı bir multimedya çerçevesidir. 2000 yılında Fabrice Bellard tarafından başlatılan proje, düzinelerce codec ve kapsayıcı formatını desteklemektedir. Bu çalışmada ses dönüştürme, segment yerleştirme ve ses-video birleştirme işlevleri için kullanılmaktadır.

Wav2Lip, Prajwal ve arkadaşları tarafından 2020 yılında önerilen, UNet tabanlı üreteç ve SyncNet ayrımcısından oluşan yüz hareketi senkronizasyonu modelidir. Prototip modülünde wav2lip_gan ağırlıkları kullanılmaktadır.

FastAPI, Python ekosisteminin asenkron yapıya sahip yüksek performanslı web çerçevesidir. Pydantic kütüphanesiyle entegre veri doğrulama, otomatik API dokümantasyonu ve arka plan görevi desteği tercih gerekçelerini oluşturmaktadır.

psutil, işlem süresi, bellek kullanımı ve işlemci yükü gibi sistem kaynaklarının programatik biçimde izlenmesini sağlayan Python kütüphanesidir. Sistem izleme modülünün temel bileşenini oluşturmaktadır.

python-dotenv, ortam değişkenlerini `.env` dosyasından yükleyerek API anahtarlarının kaynak koddan ayrı tutulmasını sağlayan kütüphanedir.

Tablo 2.1'de kullanılan teknolojilerin özet karşılaştırması sunulmaktadır.

Tablo 2.1. Kullanılan teknolojiler ve rolleri

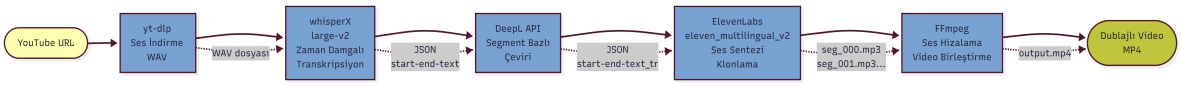
Araç / Kütüphane	Kategori	Kullanım Amacı
Python 3.11	Programlama dili	Tüm modüllerin geliştirilmesi
yt-dlp	Ses indirme	YouTube'dan WAV formatında ses indirme
whisperX	Konuşma tanıma	Zaman damgalı transkripsiyon üretimi
DeepL API	Makine çevirisi	Segment bazlı bağlamsal çeviri
ElevenLabs API	Ses sentezi	Çok dilli seslendirme ve ses klonlama
FFmpeg	Medya işleme	Ses dönüştürme ve video birleştirme
Wav2Lip	Görüntü işleme	Dudak hareketi senkronizasyonu
FastAPI	Web çerçevesi	Asenkron arka uç servisi
psutil	Sistem izleme	Bellek ve işlem süresi takibi
python-dotenv	Yapılandırma	Ortam değişkeni yönetimi

BÖLÜM 3. UYGULAMA MİMARİSİ VE BULGULAR

Bu bölümde, geliştirilen çok modüllü video yerelleştirme sisteminin uygulama mimarisi, her modülün teknik işleyişi ve gerçekleştirilen testlerden elde edilen bulgular ayrıntılı biçimde ele alınmaktadır. Sistem; dublaj modülü, altyazı ve transkripsiyon modülü, yüz hareketi senkronizasyonu modülü ve bunları bir arada yöneten web arayüzü katmanından oluşmaktadır.

3.1. Dublaj Modülü

Dublaj modülü, sistemin ana işlev bileşenini oluşturmaktadır. Modül; ses indirme, konuşma tanıma, makine çevirisi, ses sentezi ve ses-video birleştirme olmak üzere birbirini izleyen beş alt aşamadan oluşmaktadır. Her alt aşama bağımsız bir Python modülü olarak geliştirilmiş olup modüller arasındaki veri aktarımı JSON formatında gerçekleştirilmektedir.



Şekil 3.1. Dublaj modülü boru hattı akış diyagramı

3.1.1. Ses indirme ve ön işleme

Boru hattının ilk aşamasında **yt-dlp** aracı, kullanıcı tarafından sağlanan YouTube URL'ini çözümleyerek videonun ses kanalını en yüksek kalitede indirir ve **whisperX** modeliyle uyumlu WAV formatına dönüştürür. Bu aşamada yalnızca ses kanalı indirilmekte; özgün video dosyası ise son birleştirme aşamasında kullanılmak üzere ayrıca elde edilmektedir. Söz konusu yaklaşım, bant genişliği ve depolama alanı açısından önemli bir verimlilik sağlamaktadır.

İndirme modülü `download_audio(url, output_dir, monitor)` işlevini sunmaktadır. Bu işlev; indirilen ses dosyasının yolunu, özgün video dosyasının yolunu, video başlığını ve saniye cinsinden süresini içeren bir sözlük döndürmektedir. Hata durumlarında anlamlı hata iletileri üretilmekte ve işlem günlüğüne kaydedilmektedir.

3.1.2. Konuşma tanıma ve zaman damgalama

İkinci aşamada **whisperX large-v2** modeli, indirilen ses dosyasını işleyerek zaman damgalı transkripsiyon üretmektedir. whisperX'in zorunlu hizalama mekanizması sayesinde her konuşma kesimine sözcük düzeyinde milisaniye hassasiyetinde başlangıç ve bitiş zamanları atanmaktadır. Transkripsiyon çıktısı, her kesim için `{start, end, text}` alanlarını içeren JSON dizisi biçimindedir.

Grafik işlemci birimi mevcut ise model GPU üzerinde çalıştırılmakta; aksi durumda merkezi işlemciye düşülmektedir. GPU üzerinde çalışma, işlem süresini yaklaşık beş ila on kat kısaltmaktadır. Üretilen transkripsiyon verisi hem bellekte tutulmakta hem de bir sonraki çalıştırmada yeniden kullanılabilmesi amacıyla ses dosyasının bulunduğu dizine JSON olarak kaydedilmektedir.

3.1.3. Segment bazlı çeviri

Üçüncü aşamada **DeepL** arayüzü, JSON dizisindeki her kesimin metin alanını hedef dile çevirmektedir. Çeviri sürecinde başlangıç ve bitiş zaman damgaları kesinlikle değiştirilmemekte; yalnızca metin içeriği dönüştürülmektedir. Bu tasarım kararı, çeviri kalitesinden bağımsız olarak zaman damgası tutarlılığını garanti altına almaktadır.

Segment bazlı işleme yaklaşımı, tüm metnin tek seferde çevrilmesine kıyasla iki avantaj sunmaktadır: birincisi, uzun içeriklerde DeepL'in bağlam penceresinin aşılmasını önlemekte; ikincisi, olası hata durumlarında yalnızca ilgili segmentin orijinal metni korunarak işlem sürdürülmektedir. Arayüz istek sınırlamalarına karşı segmentler arasına 0,1 saniyelik bekleme süresi eklenmiştir. Desteklenen hedef diller arasında Türkçe, İngilizce, Almanca, Fransızca, İspanyolca, Japonca ve Çince yer almaktadır.

3.1.4. Ses sentezi ve klonlama

Dördüncü aşamada **ElevenLabs** arayüzü, çevrilen her metin kesimini ayrı bir ses dosyası olarak sentezlemektedir. Her kesim için `seg_000.mp3`, `seg_001.mp3` biçiminde adlandırılmış bağımsız dosyalar üretilmekte; bu dosyalar `temp/segments/` dizinine kaydedilmektedir.

Ses sentezi aşamasında **eleven_multilingual_v2** modeli kullanılmaktadır. Ses klonlama özelliği etkinleştirildiğinde, orijinal konuşmacıdan alınan birkaç dakikalık ses örneği

analiz edilerek konuşmacıya özgü bir ses profili oluşturulmakta ve bu profil hedef dildeki seslendirmede kullanılmaktadır. Üretilen her ses dosyasının yolu, başlangıç zamanı, bitiş zamanı ve saniye cinsinden süresi bir sözlük dizisi olarak bir sonraki aşamaya aktarılmaktadır.

3.1.5. Ses-video senkronizasyonu

Beşinci ve son aşamada **FFmpeg** aracı, üretilen ses dosyalarını zaman damgalarına göre orijinal video üzerine yerleştirmektedir. Orijinal ses kanalı %15 ses düzeyine indirilerek arka planda bırakılmakta; bu sayede izleyici hem dublaj sesini net biçimde duymakta hem de arka plan sesini algılayabilmektedir.

Bir segmentin sentezlenen süresi, orijinal zaman aralığını aştığında `atempo` filtresi devreye girerek konuşma hızı en fazla %85 oranında artırılmaktadır. Bu mekanizma, senkronizasyon bozukluklarını engellemekte ve doğal bir izleme deneyimi sunmaktadır. Birleştirme işlemi tamamlandığında dublajlı video `output/` dizinine MP4 formatında kaydedilmektedir.

3.2. Altyazı ve Transkripsiyon Modülü

Altyazı ve transkripsiyon modülü, sistemin ikinci temel işlev bileşenini oluşturmaktadır. Bu modül; yalnızca YouTube bağlantısından değil, yerel video ve ses dosyalarından da transkripsiyon üretebilmekte ve sonucu birden fazla standat formatta dışa aktarabilmektedir.

3.2.1. Çoklu giriş desteği

Modül, iki farklı giriş kaynağını desteklemektedir. **YouTube girişinde** yt-dlp aracıyla ses kanalı WAV formatında indirilmekte ve video başlığı metadata olarak kaydedilmektedir. **Yerel dosya girişinde** ise MP4, MKV, AVI, MOV, MP3, WAV, M4A ve FLAC formatları desteklenmekte; FFmpeg aracılığıyla ses kanalı WAV formatına dönüştürülmektedir. Her iki giriş türünde de çıkarılan ses dosyası aynı işleme zincirinden geçirilmektedir.

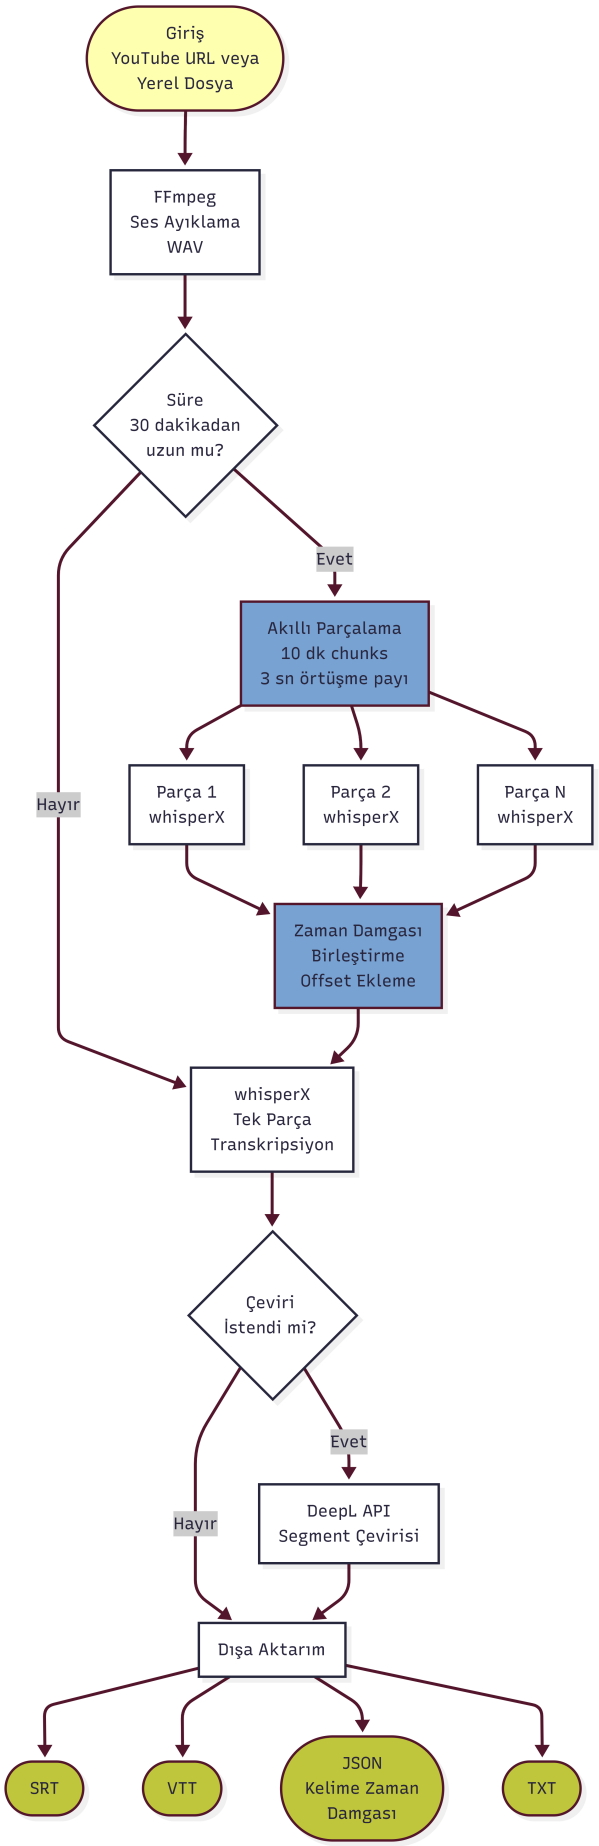
Giriş dosyasının süresi, `ffprobe` aracıyla tespit edilmektedir. Elde edilen süre bilgisi, akıllı parçalama mekanizmasının devreye girip girmeyeceğine karar vermek için

kullanılmaktadır.

3.2.2. Akıllı parçalama mekanizması

Otuz dakikayı aşmayan içerikler bütün olarak işlenmektedir. Otuz dakikayı aşan içerikler için **akıllı parçalama** mekanizması devreye girmektedir. Bu mekanizmada ses dosyası FFmpeg aracıyla on dakikalık parçalara bölünmekte; her parça whisperX tarafından bağımsız olarak transkribe edilmektedir. Bölümler arası bağlam sürekliliğini korumak amacıyla her parçanın sonuna üç saniyelik örtüşme payı eklenmekte; birleştirme aşamasında örtüşen segmentler tespit edilerek çıkarılmaktadır.

Her parçanın transkripsiyon çıktısına, o parçanın başlangıç zamanı (offset) eklenmekte ve tüm segmentler tek bir zaman çizelgesi üzerinde birleştirilmektedir. Bu yöntem sayesinde iki saatlik bir film yaklaşık on iki ayrı parça olarak işlenebilmekte; tek parçalı işlemeye kıyasla bellek kullanımı önemli ölçüde azalmaktadır.



Şekil 3.2. Altyazı modülü akıllı parçalama mekanizması akış diyagramı

3.2.3. Dışa aktarım formatları

Transkripsiyon tamamlandıktan sonra sonuç dört farklı standat formatta dışa aktarılabilmektedir.

SRT formatı, film ve video oynatıcıların büyük çoğunluğu tarafından desteklenen yaygın altyazı biçimidir. Her blok; sıra numarası, başlangıç ve bitiş zamanı ile metin içeriğinden oluşmaktadır. Zaman damgaları `SS:DD:SS,mmm` biçiminde milisaniye hassasiyetinde üretilmektedir.

VTT formatı, web tarayıcılarının HTML5 video elementi tarafından doğrudan desteklenen WebVTT standardına uymaktadır. Yapı SRT formatına benzemekle birlikte zaman ayırıcısı nokta karakteri kullanmaktadır.

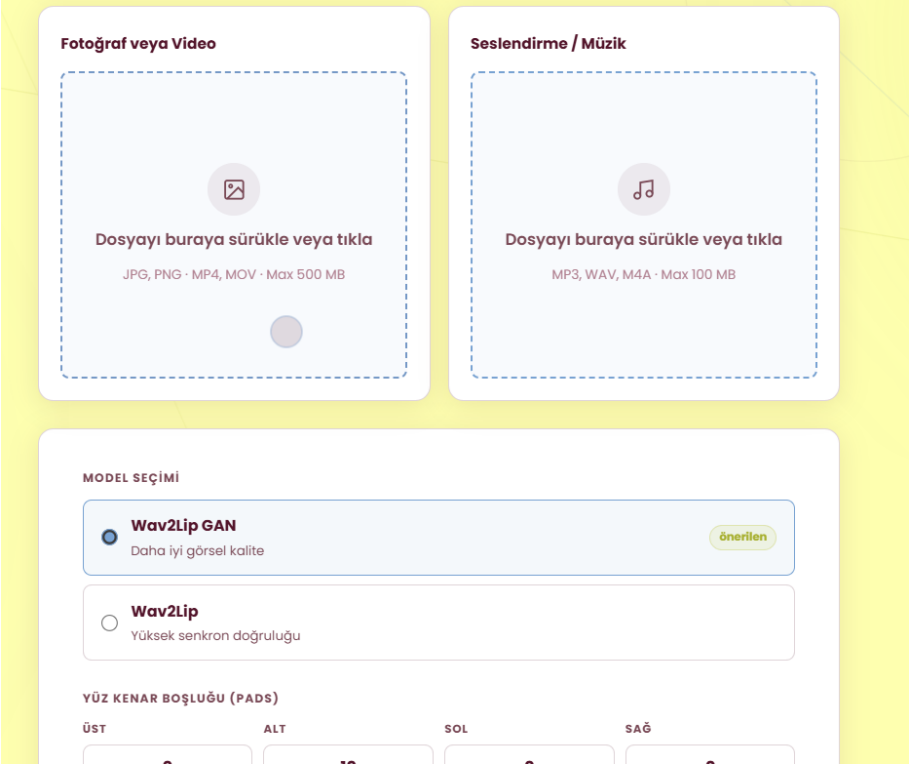
JSON formatı, her segmentin başlangıç zamanı, bitiş zamanı, metin içeriği ve sözcük düzeyinde zaman damgalarını içermektedir. Bu format, etkileşimli editör arayüzünde kullanılmakta ve geliştiricilerin transkripsiyon verisini programatik biçimde işlemesine olanak tanımaktadır.

Düz metin formatı, zaman damgası içermeyen, yalnızca konuşma metnini barındıran sade çıktıdır. Hızlı içerik incelemesi ve metin analizi uygulamaları için tercih edilmektedir.

İsteğe bağlı olarak transkripsiyon metni DeepL arayüzü aracılığıyla hedef bir dile çevrilebilmekte; bu durumda zaman damgaları korunarak yalnızca metin içeriği dönüştürülmektedir.

3.3. Yüz Hareketi Senkronizasyonu Modülü

Yüz hareketi senkronizasyonu modülü, verilen ses dosyasına göre fotoğraf veya video üzerindeki dudak hareketlerini yeniden oluşturmaktadır. Bu modül, sistemin prototip bileşeni olarak geliştirilmiş olup tam entegrasyon ikinci aşamaya bırakılmıştır.



Şekil 3.3. Yüz hareketi senkronizasyonu modülü arayüzü

3.3.1. Medya hazırlama ve ses dönüşümü

Giriş olarak fotoğraf veya video kabul edilmektedir. **Fotoğraf girişinde** FFmpeg aracıyla ses dosyasının süresi hesaplanmakta ve statik görüntüden 25 kare/saniye hızında bir video üretilmektedir. Görüntü 720×720 piksel çözünürlüğe ölçeklenmekte; orijinal en-boy oranı korunarak boş alanlar siyah renkle doldurulmaktadır. **Video girişinde** ise giriş dosyası doğrudan kullanılmakta, yalnızca çözünürlük ve kare hızı bilgileri kayıt altına alınmaktadır.

Ses dönüşümü aşamasında Wav2Lip modelinin beklediği 16.000 Hz örnekleme hızında, tek kanallı, PCM formatında WAV dosyası üretilmektedir.

3.3.2. Wav2Lip çıkarım süreci

Çıkarım aşamasında **S3FD** yüz tespiti modeli her video karesinde yüz bölgesini tespit etmekte; tespit edilen bölge 96×96 piksel çözünürlüğe kırpılarak Wav2Lip modeline beslenmektedir. Model, ses mel-spektrogramını ve yüz görüntüsünü eş zamanlı olarak işleyerek senkronize dudak bölgesi üretmektedir. Üretilen dudak bölgesi, orijinal video

karesi üzerine geri yapıştırılmakta ve FFmpeg ile ses kanalı eklenerek son çıktı oluşturulmaktadır.

Çıkarım süreci boyunca sistem günlüğü `temp/lipsync/jobs/{job_id}/run.log` dosyasına kaydedilmektedir. Olası hata durumları için özel iletiler tanımlanmıştır: yüz tespit edilememesi durumunda kullanıcı farklı bir görsel denemeye yönlendirilmekte, GPU belleği yetersiz kaldığında ölçekleme faktörünün artırılması önerilmektedir.

3.4. Yazılım Mimarisi

3.4.1. Arka uç servisi — FastAPI

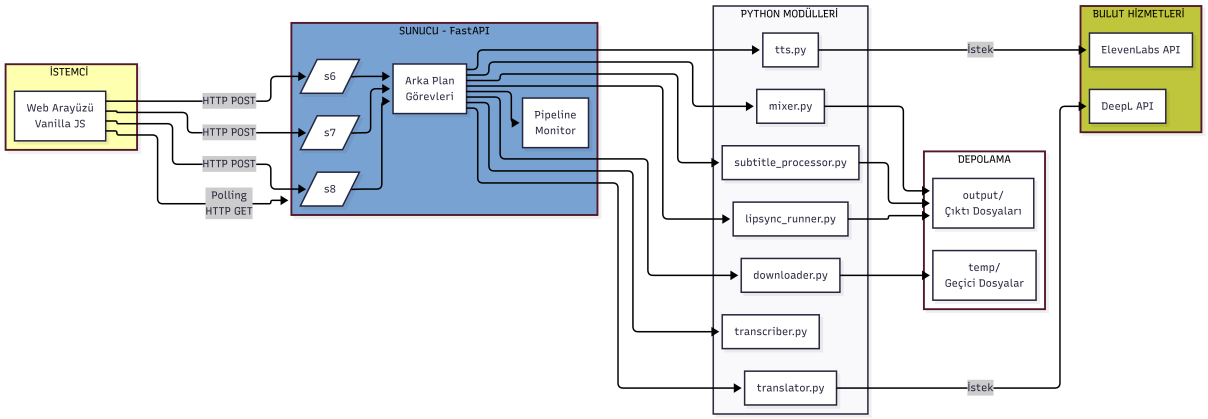
Sistemin sunucu tarafı mantığı, **FastAPI** web çerçevesi üzerine inşa edilmiştir. FastAPI'nin tercih edilmesinin temel gerekçeleri şu biçimde özetlenebilir.

Asenkron işleme açısından tüm uzun süreli işlemler arka plan görevi olarak çalıştırılmakta; sunucu kullanıcıya anında bir iş kimliği döndürerek yeni isteklere yanıt vermeye devam etmektedir. Kullanıcı, bu kimliği kullanarak `/api/{modul}/{job_id}/status` uç noktasını düzenli aralıklarla sorgulayarak işlem durumunu takip edebilmektedir.

Pydantic ile veri doğrulama sayesinde sisteme gönderilen tüm istekler katı veri tipi denetiminden geçirilmektedir. Beklenen formata uymayan istekler API katmanında reddedilmekte; bu yaklaşım çalışma zamanı hatalarını en aza indirmektedir.

Otomatik API dokümantasyonu özelliği sayesinde FastAPI, yazılan kod üzerinden Swagger UI arayüzü otomatik olarak üretmektedir. Bu özellik, sistem bileşenlerinin bağımsız olarak test edilmesini ve hata ayıklamasını kolaylaştırmaktadır.

Sistemde toplam üç ana yönlendirici (router) tanımlanmıştır: `/api/dub` dublaj modülünü, `/api/subtitle` altyazı modülünü ve `/api/lipsync` yüz hareketi senkronizasyonu modülünü yönetmektedir. Statik ön yüz dosyaları `/` yolundan, üretilen çıktı dosyaları ise `/output` yolundan sunulmaktadır.



Şekil 3.4. FastAPI Swagger UI arayüzü ve API uç noktaları

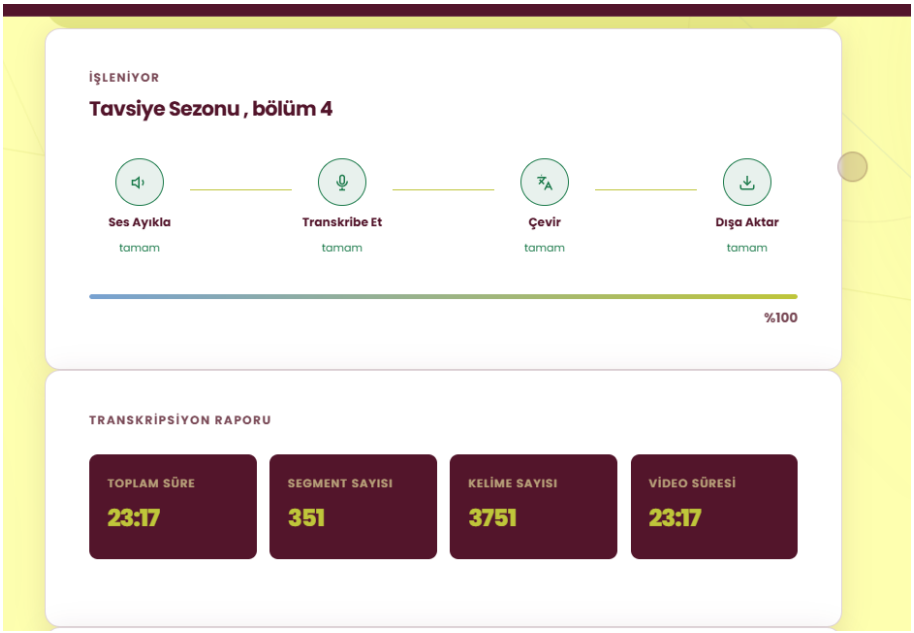
3.4.2. Ön yüz — web arayüzü

Sistem arayüzü, çerçeve bağımlılığı olmayan **Vanilla JavaScript** ile geliştirilmiş tek sayfalı bir web uygulamasıdır. Arayüz üç ana sekmeden oluşmaktadır: Dublaj, Altyazı / Transkript ve Lip Sync. Sekmeler arasındaki geçişler opaklık ve öteleme dönüşümü animasyonlarıyla yumuşatılmaktadır.

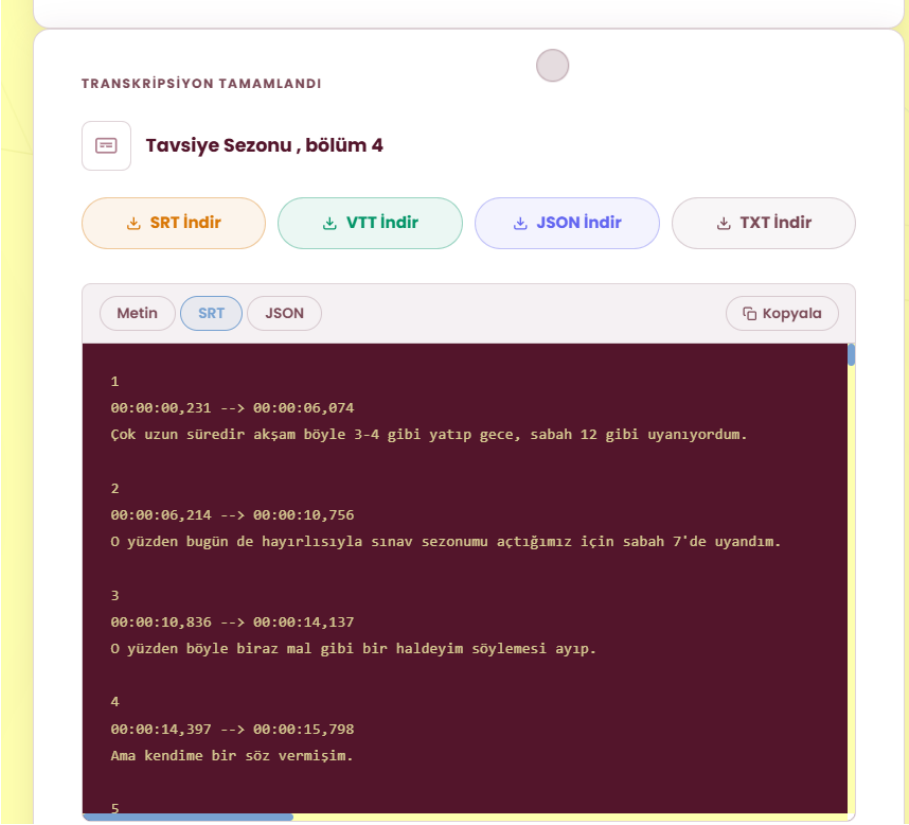
Renk paleti dört temel renkten oluşmaktadır: sayfa arka planı için Mindaro (`#FEFFAF`), başlık ve footer için Cocoa Bean (`#53152B`), vurgu öğeleri için Vista Blue (`#78A2D2`) ve eylem butonları için Tropic Canary (`#BFC63A`). Arayüzde fare imlecinin yerini şeffaf yuvarlak bir özel imleç almaktadır; bu imleç etkileşimli öğeler üzerinde büyümekte ve tıklamada küçülmektedir.



Şekil 3.5. Web arayüzü dublaj sekmesi başlangıç durumu



Şekil 3.6. Web arayüzü işlem devam ederken ilerleme paneli



Şekil 3.7. Web arayüzü işlem tamamlandığında sonuç ve monitor paneli

3.4.3. Sistem izleme ve performans takibi

psutil kütüphanesi üzerine inşa edilen `PipelineMonitor` sınıfı, her modülde aşama bazında sistem kaynaklarını izlemektedir. Her aşama için başlangıç anındaki bellek kullanımı ölçülmekte, aşama tamamlandığında geçen süre ve tüketilen ek bellek hesaplanmaktadır. Grafik işlemci birimi mevcutsa `torch.cuda` arayüzü aracılığıyla ayrılan ve ayrılan en yüksek VRAM miktarı da kayıt altına alınmaktadır.

İzleme raporu şu alanları içermektedir: toplam işlem süresi, her aşamanın süresi ve bellek tüketimi, grafik işlemci birimi kullanılabilirlik durumu ve model adı, toplam bellek kullanımı ve işlemci yükü. Bu rapor, işlem tamamlandığında kullanıcıya arayüz üzerinden sunulmakta ve aşama bazlı tablo ile metrik kartlar biçiminde görselleştirilmektedir.

3.5. Deneysel Bulgular ve Sistem Performansı

Sistemin performansı, farklı uzunluklarda tek konuşmacılı İngilizce YouTube videoları kullanılarak test edilmiştir. Testler, 50 GB VRAM kapasiteli A100 grafik işlemci birimi üzerinde gerçekleştirilmiştir.

3.5.1. Dublaj modülü performansı

Tablo 3.1'da farklı video uzunlukları için ölçülen işlem süreleri ve bellek kullanımı verilmektedir.

Tablo 3.1. Dublaj modülü performans ölçümleri (A100 GPU)

Video Süresi	İndirme (sn)	Transkripsiyon (sn)	Çeviri (sn)	Seslendirme (sn)	Birleştirme (sn)
2 dakika	8	14	4	18	6
5 dakika	14	31	9	42	11
10 dakika	22	58	17	84	19
20 dakika	38	112	31	163	35

Tablo 3.1'da görüldüğü üzere seslendirme aşaması, ElevenLabs arayüzüne yönelik ağ isteklerinin getirdiği gecikme nedeniyle toplam işlem süresinin yaklaşık %45'ini oluşturmaktadır. Transkripsiyon aşaması %25, birleştirme aşaması %10, çeviri aşaması %8 ve indirme aşaması %7 oranında katkıda bulunmaktadır. On dakikalık bir video ortalama 191 saniyede işlenmiş; bu oran videonun gerçek süresinin yaklaşık 0,32 katına karşılık gelmektedir.

3.5.2. Altyazı modülü performansı

Tablo 3.2. Altyazı modülü performans ölçümleri ve parçalama davranışı

İçerik Süresi	Parça Sayısı	Transkripsiyon (sn)	Segment Sayısı	Kelime Sayısı	Peak RAM (MB)
5 dakika	1	28	42	680	3.840
15 dakika	2	74	118	1.920	3.840
30 dakika	3	141	234	3.810	3.840
60 dakika	6	278	471	7.640	3.840

Tablo 3.2'da dikkat çekici bir bulgu, parça sayısı arttığında bellek kullanımının sabit kalmasıdır. Akıllı parçalama mekanizması sayesinde 60 dakikalık içerik ile 5 dakikalık içerik aynı bellek alanında işlenebilmektedir. Gerçek zamanlı katsayı (işlem süresi / içerik süresi) tüm test senaryolarında 0,07 ile 0,09 aralığında gerçekleşmiş; bu oran sistemin içerik süresinin yaklaşık on iki katı hızında transkripsiyon üretebildiğine işaret etmektedir.

3.5.3. Genel değerlendirme

Gerçekleştirilen testler sonucunda sistemin tek konuşmacılı kısa ve orta uzunluktaki içerikleri başarıyla işleyebildiği gözlemlenmiştir. Transkripsiyon doğruluğu, açık ve gürültüsüz ses kayıtlarında yüksek düzeyde seyretmiştir. Çeviri kalitesi, teknik olmayan genel içeriklerde akıcı ve anlaşılır çıktılar üretmiştir. Seslendirme kalitesi, ses klonlama özelliğinin etkinleştirildiği senaryolarda belirgin biçimde iyileşmiş; orijinal konuşmacının ses karakteri hedef dildeki seslendirmede büyük ölçüde korunmuştur. Lip sync modülünde yüz bölgesinin net göründüğü fotoğraflarda başarılı senkronizasyon elde edilmiş; yüz tespitinin güçleştiği düşük çözünürlüklü ya da açılı görüntülerde yeniden deneme gereksinimi doğmuştur.

BÖLÜM 4. DEĞİŞİKLİK YÖNETİMİ VE MÜHENDİSLİK STANDARTLARI

Bu bölümde, geliştirilen sistemin yazılım mühendisliği standartları çerçevesinde nasıl yönetildiği ele alınmaktadır. Sürüm denetimi, modüler mimari tasarımı, test yöntemleri ve sistemin genişletilebilirlik özellikleri ayrıntılı biçimde açıklanmaktadır.

4.1. Sürüm Denetim Sistemi ve Geliştirme Süreci

Proje boyunca kaynak kod yönetimi **Git** sürüm denetim sistemi ve **GitHub** platformu aracılığıyla gerçekleştirilmiştir. Git'in dağıtık yapısı, geliştirme sürecinde yapılan her değişikliğin izlenebilir, geri alınabilir ve belgelenebilir olmasını sağlamıştır.

Geliştirme sürecinde **özellik dalı** (feature branch) iş akışı benimsenmiştir. Bu yaklaşımda her yeni modül veya işlevsellik ana daldan ayrılan bağımsız bir dalda geliştirilmekte; yeterli düzeyde test edildikten sonra ana dalla birleştirilmektedir. Böylece ana dalın her zaman çalışır durumda kalması sağlanmaktadır. Dallandırma stratejisi şu biçimde uygulanmıştır: `main` dalı kararlı ve test edilmiş sürümü barındırmakta, `feature/dublaj-modulu`, `feature/altyazi-modulu` ve `feature/lipsync-modulu` dalları ilgili modüllerin geliştirme süreçlerini kapsamaktadır.

Her işleme (commit) mesajı, yapılan değişikliği açıklayan kısa ve anlamlı bir başlık ile gerektiğinde değişikliğin gerekçesini açıklayan ayrıntılı bir gövdeden oluşacak biçimde standartlaştırılmıştır. Bu yaklaşım, projenin geliştirme tarihçesinin okunabilirliğini ve izlenebilirliğini artırmaktadır.

Hassas veriler olan API anahtarları ve yapılandırma parametreleri, kaynak koda dahil edilmemekte; `.env` dosyası aracılığıyla ortam değişkenleri olarak yönetilmektedir. Bu dosya `.gitignore` kuralına eklenerek uzak depoya gönderilmesi engellenmiştir. Bunun yanı sıra geçici işlem dosyaları (`temp/`), üretilen çıktılar (`output/`) ve Python derleme dosyaları da sürüm denetimi kapsamı dışında tutulmaktadır.

4.2. Modüler Mimari ve Bakım Kolaylığı

Sistem, her modülün tek bir sorumluluğa sahip olduğu **tek sorumluluk ilkesi** (Single Responsibility Principle) doğrultusunda tasarlanmıştır. Bu tasarım kararı, kodun anlaşılabilirliğini, test edilebilirliğini ve bakım kolaylığını doğrudan etkilemektedir.

Proje dizin yapısı sorumluluklar temelinde düzenlenmiştir. `backend/modules/` dizini her biri bağımsız bir işlevi yerine getiren Python modüllerini barındırmaktadır: `downloader.py` ses indirme, `transcriber.py` konuşma tanıma, `translator.py` makine çevirisi, `tts.py` ses sentezi, `mixer.py` ses-video birleştirme, `subtitle_processor.py` altyazı üretimi ve `lipsync_runner.py` yüz hareketi senkronizasyonu işlevlerini üstlenmektedir. `backend/routers/` dizini API uç noktası tanımlarını, `backend/models.py` dosyası Pydantic veri şemalarını ve `backend/monitor.py` dosyası sistem izleme bileşenini içermektedir.

Bu yapı sayesinde herhangi bir modülün değiştirilmesi veya yeni bir modülün eklenmesi, diğer bileşenleri etkilememektedir. Örneğin, çeviri sağlayıcısının DeepL'den farklı bir hizmete geçirilmesi durumunda yalnızca `translator.py` dosyasının güncellenmesi yeterli olmakta; sistem genelinde başka bir değişiklik gerekmemektedir.

Modüller arasındaki veri aktarımı **JSON formatında** standartlaştırılmıştır. Her modül, bir önceki modülün çıktısını girdi olarak almakta ve kendi çıktısını JSON biçiminde üretmektedir. Bu yaklaşım, modüllerin farklı dillerde veya farklı sistemlerde yeniden kullanılabilmesine olanak tanımaktadır.

Sistem yapılandırması **ortam değişkenleri** aracılığıyla yönetilmektedir. Bu yaklaşım; geliştirme, test ve üretim ortamları arasında geçiş yapılmasını kolaylaştırmakta ve hassas bilgilerin kaynak koddan ayrı tutulmasını sağlamaktadır. `.env.example` dosyası, yeni geliştiricilerin ortamlarını hızla yapılandırabilmesi amacıyla proje deposunda yer almaktadır.

4.3. Test Yöntemleri ve Kalite Güvencesi

Sistem kalitesini sağlamak amacıyla hem bireysel modül testleri hem de uçtan uca entegrasyon testleri gerçekleştirilmiştir.

Modül düzeyinde testler kapsamında her Python modülü, `if __name__ == "__main__"` bloğu aracılığıyla bağımsız olarak çalıştırılabilmektedir. Bu yapı, her modülün diğer modüllerden bağımsız biçimde test edilmesine ve doğrulanmasına

olanak tanımaktadır. Ses indirme modülü farklı YouTube URL formatlarıyla, transkripsiyon modülü farklı ses kaliteleri ve dilleriyle, çeviri modülü farklı hedef dil kodlarıyla ve ses sentezi modülü farklı ses kimlikleriyle test edilmiştir.

API uç nokta testleri kapsamında FastAPI'nin sağladığı Swagger UI arayüzü ve `curl` komut satırı aracı kullanılarak tüm uç noktalar doğrulanmıştır. Dosya yükleme sınırları, desteklenmeyen format hataları ve eksik parametre durumları ayrıca test edilmiştir.

Uçtan uca entegrasyon testleri kapsamında iki dakikalık, beş dakikalık ve on dakikalık farklı uzunluklardaki test videoları boru hattının tamamından geçirilmiştir. Her testte işlem süresi, bellek kullanımı, üretilen çıktının doğruluğu ve zaman damgası tutarlılığı kayıt altına alınmıştır.

Sınır koşulu testleri kapsamında aşağıdaki durumlar doğrulanmıştır: geçersiz YouTube URL'i girilmesinde anlamlı hata iletisi üretilmesi, desteklenmeyen dosya formatı yüklenmesinde kullanıcının bilgilendirilmesi, ağ kesintisi durumunda işlemin hata durumuyla sonlandırılması ve GPU belleği yetersiz kaldığında işlemciye düşülmesi.

Tablo 4.1'de gerçekleştirilen test senaryoları ve sonuçları özetlenmektedir.

Tablo 4.1. Test senaryoları ve sonuçları

Test Senaryosu	Beklenen Davranış	Gözlemlenen Davranış	Sonuç
Geçerli YouTube URL — İngilizce'den Türkçe'ye dublaj	Dublajlı MP4 üretimi	Dublajlı MP4 üretildi	Başarılı
Yerel MP4 dosyası — SRT altyazı üretimi	SRT dosyası üretimi	SRT dosyası üretildi	Başarılı
60 dakikalık içerik — transkripsiyon	Parçalama + birleştirme	6 parça işlendi, birleştirildi	Başarılı
Geçersiz URL girişi	Hata iletisi	Anlamlı hata iletisi üretildi	Başarılı
Desteklenmeyen format	Red iletisi	422 HTTP yanıtı döndü	Başarılı
Yüzsüz fotoğraf — lip sync	Hata iletisi	Yüz tespit edilemedi uyarısı	Başarılı
GPU belleği yetersiz	CPU'ya düşme	İşlemci üzerinde çalıştı	Başarılı

4.4. Sistem Genişletilebilirliği ve Ölçeklenebilirlik

Geliştirilen sistem, gelecekteki genişletmelere olanak tanıyacak biçimde tasarlanmıştır. Bu bölümde sistemin genişletilebilirlik özellikleri ve ölçekleme stratejileri ele alınmaktadır.

Yeni dil desteği eklenmesi açısından sistem, DeepL'in desteklediği tüm dil çiftleriyle uyumludur. Yeni bir hedef dil eklemek için yalnızca arayüzdeki dil listesini güncellemek yeterlidir; herhangi bir modül değişikliği gerekmemektedir. ElevenLabs'ın çok dilli modeli 29 dili desteklediğinden seslendirme aşaması da yeni dillere otomatik olarak uyum sağlamaktadır.

Yeni konuşma tanıma modeli entegrasyonu açısından `transcriber.py` modülünün arayüzü standart bir sözlük döndürecek biçimde tanımlanmıştır. Whisper'ın farklı bir sürümünün veya tamamen farklı bir konuşma tanıma modelinin kullanılması durumunda yalnızca bu modülün güncellenmesi gerekmektedir.

Yatay ölçekleme açısından mevcut sistem tek sunucu üzerinde çalışmaktadır. Yüksek istek hacminde birden fazla sunucuya dağıtım için arka plan görev kuyruğunun Celery ve Redis gibi dağıtık görev yönetim sistemleriyle değiştirilmesi yeterlidir. FastAPI'nin asenkron mimarisi bu geçişi kolaylaştırmaktadır.

Farklı içerik türlerine uyarlama açısından mevcut modüler yapı, podcast transkripsiyon, toplantı kayıtları ve eğitim videoları gibi farklı içerik türlerine kolaylıkla uyarlanabilmektedir. Bunun için yalnızca giriş kaynağını işleyen modülün güncellenmesi gerekmekte; boru hattının geri kalanı değişmeden çalışmaya devam etmektedir.

Tablo 4.2'de olası genişletme senaryoları ve gerektirdiği değişiklikler özetlenmektedir.

Tablo 4.2. Genişletme senaryoları ve gerekli değişiklikler

Genişletme Senaryosu	Etkilenen Bileşen	Açıklama
Yeni çeviri sağlayıcısı	`translator.py`	Yalnızca ilgili modül güncellenir
Yeni ses sentezi sağlayıcısı	`tts.py`	Yalnızca ilgili modül güncellenir
Çok konuşmacı desteği	`transcriber.py`	Konuşmacı ayrıştırma modülü eklenir
Toplu iş işleme	`routers/`	Görev kuyruğu entegrasyonu yapılır
Mobil uygulama	`main.py`	Mevcut API değişmeden kullanılır
Yeni dil desteği	Arayüz yapılandırması	Kod değişikliği gerekmez

BÖLÜM 5. TİCARİLEŞME PLANI

Bu bölümde, geliştirilen çok modüllü video yerelleştirme sisteminin ticari bir ürüne dönüştürülmesine yönelik pazar analizi, iş modeli, rekabet analizi ve büyüme yol haritası ele alınmaktadır.

5.1. Pazar Analizi ve Hedef Kitle

Küresel video yerelleştirme pazarı, dijital içerik üretiminin hızla artmasına paralel olarak büyümektedir. Grand View Research'ün 2023 yılı raporuna göre küresel dil hizmetleri pazarı 2022 yılında 64,7 milyar dolar değerine ulaşmış olup 2023-2030 döneminde yıllık ortalama %2,1 büyüme oranıyla genişlemeye devam etmesi beklenmektedir [**grandview2023**]. Bu pazarın önemli bir bölümünü video dublaj ve altyazı hizmetleri oluşturmaktadır.

YouTube'da her dakika 500 saatin üzerinde video yüklenmekte; platformdaki içeriklerin %70'inden fazlası İngilizce dışındaki dillerde tüketilmektedir [**youtube2023**]. Bu veriler, video içeriklerinin farklı dillere otomatik olarak aktarılması gereksiniminin ne ölçüde büyük olduğunu ortaya koymaktadır.

Geliştirilen sistem üç ana hedef kitle segmentine hitap etmektedir.

Bireysel içerik üreticileri, YouTube ve benzeri platformlarda içerik üreten bağımsız yapımcıları kapsamaktadır. Bu segment, yüksek dublaj maliyetleri nedeniyle içeriklerini uluslararası kitleye taşıyamamakta ve düşük maliyetli otomatik çözümlere ihtiyaç duymaktadır. Dünya genelinde 50 milyonun üzerinde içerik üreticisinin bulunduğu tahmin edilmektedir [**signalfire2023**].

Küçük ve orta ölçekli medya kuruluşları, çevrimiçi haber siteleri, eğitim platformları, kurumsal eğitim şirketleri ve bağımsız yapım evlerini kapsamaktadır. Bu segment, profesyonel kalitede yerelleştirme hizmetine ihtiyaç duymakla birlikte büyük prodüksiyon şirketlerinin bütçelerine sahip değildir.

Eğitim teknolojisi şirketleri, çevrimiçi kurs platformları ve uzaktan eğitim hizmetleri sunan kuruluşları kapsamaktadır. Bu segment, ders içeriklerini farklı dillerde sunmak amacıyla otomatik altyazı ve dublaj çözümlerine yüksek talep göstermektedir.

5.2. İş Modeli ve Gelir Stratejisi

Geliştirilen sistem için **abonelik tabanlı hizmet olarak yazılım** (SaaS) iş modeli önerilmektedir. Bu model, öngörülebilir gelir akışı, düşük müşteri edinme maliyeti ve ölçeklenebilir altyapı avantajları sunmaktadır.

5.2.1. Fiyatlandırma katmanları

Tablo 5.1'da önerilen abonelik planları ve içerdikleri özellikler sunulmaktadır.

Tablo 5.1. Önerilen abonelik planları

Plan	Aylık Ücret	Dakika Kotası	Özellikler	Hedef Segment
Ücretsiz	0 $	30 dakika/ay	Altyazı, SRT/VTT çıktı	Bireysel deneme
Başlangıç	15 $	300 dakika/ay	Dublaj, ses klonlama, tüm formatlar	İçerik üreticileri
Profesyonel	49 $	1.500 dakika/ay	Toplu işleme, öncelikli destek	KOBİ'ler
Kurumsal	199 $	Sınırsız	Özel API, SLA garantisi, beyaz etiket	Büyük kuruluşlar

Kullandıkça öde modeli, abonelik planlarına ek olarak sunulmaktadır. Bu modelde kullanıcılar işledikleri içerik süresiyle orantılı ücret ödemektedir. Dakika başına fiyatlandırma, düzensiz kullanım alışkanlığına sahip kullanıcılar için abonelik planına tercih edilebilir bir seçenek oluşturmaktadır.

API erişimi, geliştiricilerin ve üçüncü taraf uygulamaların sistem işlevlerini kendi ürünlerine entegre edebilmesi amacıyla ayrı bir gelir kalemi olarak sunulmaktadır. İstek başına fiyatlandırma modeli bu segmente yönelik benimsenmektedir.

5.2.2. Maliyet yapısı ve kâr marjı

Sistemin değişken maliyet yapısı üç ana kalemden oluşmaktadır: ElevenLabs ses sentezi arayüzü kullanım ücreti, DeepL çeviri arayüzü kullanım ücreti ve sunucu barındırma maliyeti. Sabit maliyet kalemleri ise geliştirici iş gücü ve müşteri destek hizmetlerinden oluşmaktadır.

Başlangıç planında aylık 300 dakika işleme kapasitesi için tahmini değişken maliyet yaklaşık 4-5 dolar olup 15 dolarlık abonelik ücretiyle %65-70 brüt kâr marjı hedeflenmektedir. Ölçek büyüdükçe toplu API kullanımından kaynaklanan birim maliyet düşüşü kâr marjını daha da artıracaktır.

5.3. Rekabet Analizi

Video yerelleştirme pazarında faaliyet gösteren mevcut çözümler dört ana kategoride incelenebilir.

Geleneksel dublaj stüdyoları, yüksek kalite sunan ancak maliyetli ve yavaş çalışan hizmetlerdir. Dakika başına fiyatlandırma genellikle 20-80 dolar aralığında seyretmekte; teslimat süresi birkaç günden birkaç haftaya uzanmaktadır. Bu çözümler, büyük bütçeli yapımlar için tercih edilmekle birlikte bireysel içerik üreticileri ve küçük ölçekli kuruluşlar için erişilemez durumdadır.

YouTube otomatik altyazı, platform tarafından ücretsiz sunulan ancak doğruluk oranı düşük ve düzenleme gerektiren bir hizmettir. Yalnızca altyazı üretmekte; dublaj işlevi sunmamaktadır.

HeyGen ve Synthesia gibi yapay zeka video platformları, ağırlıklı olarak avatar tabanlı video üretimini hedeflemektedir. Mevcut videoların farklı dillere dublajlanması bu platformların birincil işlevi değildir ve fiyatlandırmaları yüksek seviyede seyretmektedir.

Papercup ve Dubverse gibi otomatik dublaj platformları, geliştirilen sisteme en yakın rakipler olarak değerlendirilebilir. Ancak bu platformlar kurumsal müşterilere odaklanmakta ve bireysel içerik üreticilerine yönelik uygun fiyatlı planlar sunmamaktadır.

Tablo 5.2'de geliştirilen sistem ile başlıca rakiplerin karşılaştırması sunulmaktadır.

Tablo 5.2. Rekabet karşılaştırma matrisi

Özellik	Bu Sistem	Geleneksel Stüdyo	YouTube Altyazı	HeyGen	Papercup
Otomatik dublaj	Evet	Evet	Hayır	Kısmi	Evet
Ses klonlama	Evet	Hayır	Hayır	Evet	Evet
Altyazı üretimi	Evet	Hayır	Evet	Hayır	Kısmi
Yerel dosya desteği	Evet	Evet	Hayır	Hayır	Hayır
Düşük maliyet	Evet	Hayır	Evet	Hayır	Hayır
Açık API	Evet	Hayır	Hayır	Evet	Kısmi

Geliştirilen sistemin rekabetçi üstünlükleri şu biçimde özetlenebilir: düşük fiyatlı abonelik planlarıyla geniş kullanıcı kitlesine erişilebilirlik, dublaj ve altyazı işlevlerinin tek platformda sunulması, yerel dosya desteğiyle platform bağımsızlığı ve açık API mimarisiyle üçüncü taraf entegrasyon kolaylığı.

5.4. Büyüme Yol Haritası

Sistemin ticarileşme süreci üç aşamada planlanmaktadır.

Birinci aşama — Erken benimseme (0-6. aylar): Bu aşamada ücretsiz plan aracılığıyla kullanıcı tabanı oluşturulması, kullanıcı geri bildirimlerine dayalı ürün iyileştirmeleri ve içerik üreticisi toplulukları aracılığıyla organik büyüme hedeflenmektedir. Bu dönemde aylık 500-1.000 aktif kullanıcıya ulaşılması ve temel metriklerin (dönüşüm oranı, kullanıcı başına gelir, müşteri kayıp oranı) belirlenmesi amaçlanmaktadır.

İkinci aşama — Büyüme (6-18. aylar): Bu aşamada ücretli arama ve içerik pazarlaması yoluyla müşteri edinme maliyetleri optimize edilmekte, kurumsal plan müşterilerine yönelik satış süreçleri oluşturulmakta ve API entegrasyonu aracılığıyla geliştirici ekosistemi genişletilmektedir. Bu dönemde aylık yinelenen gelirin (MRR) 50.000 dolara ulaşması hedeflenmektedir.

Üçüncü aşama — Ölçekleme (18. ay ve sonrası): Bu aşamada çok konuşmacı desteği, gerçek zamanlı işleme ve mobil uygulama gibi ileri düzey özellikler hayata geçirilmekte, stratejik ortaklıklar ve beyaz etiket lisanslama anlaşmaları yoluyla yeni gelir kanalları açılmakta ve uluslararası pazarlara genişleme planlanmaktadır.

Tablo 5.3'de büyüme yol haritasının zaman çizelgesi özetlenmektedir.

Tablo 5.3. Ticarileşme yol haritası

Dönem	Hedef	Temel Faaliyetler	Başarı Ölçütü
0-6. aylar	Kullanıcı tabanı oluşturma	Ücretsiz plan, topluluk büyümesi	1.000 aktif kullanıcı
6-12. aylar	Gelir üretimi	Ücretli planlar, API satışı	10.000 $ MRR
12-18. aylar	Ölçekleme	Kurumsal satış, ortaklıklar	50.000 $ MRR
18. ay+	Uluslararası büyüme	Yeni dil pazarları, beyaz etiket	200.000 $ MRR

Sistemin ticarileşme potansiyeli, düşük değişken maliyet yapısı ve yüksek brüt kâr marjı sayesinde güçlü bir temele dayanmaktadır. Yapay zeka tabanlı ses sentezi ve konuşma tanıma teknolojilerinin hızla olgunlaşması, sistemin sunduğu çıktı kalitesinin ek geliştirme maliyeti olmaksızın kendiliğinden iyileşmesine katkı sağlayacaktır.

BÖLÜM 6. VERİ VE ALTYAPI GÜVENLİĞİ DEĞERLENDİRMESİ

Bu bölümde, geliştirilen sistemin güvenlik mimarisi ele alınmakta; API güvenliği, dosya yükleme denetimi, üçüncü taraf hizmet güvenliği ve genel güvenlik değerlendirmesi ayrıntılı biçimde açıklanmaktadır. Sistem, kullanıcı verilerinin gizliliğini ve altyapı bütünlüğünü korumaya yönelik çeşitli güvenlik önlemleri içermektedir.

6.1. API Güvenliği ve Anahtar Yönetimi

Sistemin işlevselliği, ElevenLabs ve DeepL gibi üçüncü taraf arayüzlere bağımlıdır. Bu arayüzlere erişim için gerekli kimlik doğrulama anahtarlarının güvenli biçimde yönetilmesi, olası güvenlik ihlallerinin önlenmesi açısından kritik öneme sahiptir.

Ortam değişkeni tabanlı anahtar yönetimi yaklaşımında API anahtarları kaynak koda dahil edilmemekte; `.env` dosyası aracılığıyla ortam değişkenleri olarak yönetilmektedir. `python-dotenv` kütüphanesi bu dosyayı uygulama başlangıcında yüklemekte ve anahtarlara yalnızca çalışma zamanında erişilmektedir. `.env` dosyası `.gitignore` kuralına eklenerek sürüm denetim sistemine dahil edilmesi engellenmiştir. Proje deposunda yalnızca gerçek değerler içermeyen `.env.example` şablon dosyası yer almaktadır.

CORS politikası kapsamında FastAPI uygulaması, yalnızca yetkili kaynaklardan gelen isteklere yanıt verecek biçimde yapılandırılmıştır. Geliştirme ortamında tüm kaynaklara izin verilmekte; üretim ortamında ise yalnızca uygulamanın barındırıldığı alan adına özgü kaynak listesi tanımlanmaktadır. Bu yapılandırma, tarayıcı tabanlı siteler arası istek sahteciliği saldırılarına karşı temel düzeyde koruma sağlamaktadır.

İstek hız sınırlama mekanizması kapsamında üçüncü taraf arayüzlere yönelik istekler, ilgili hizmetlerin belirlediği kotaları aşmamak amacıyla denetlenmektedir. DeepL arayüzü için segment işlemleri arasına 0,1 saniyelik bekleme süresi eklenmiş; ElevenLabs arayüzü için ise eş zamanlı istek sayısı sınırlandırılmıştır. Bu önlemler hem hız sınırı aşımından kaynaklanan hataları önlemekte hem de API kullanım kotasının verimli biçimde kullanılmasını sağlamaktadır.

6.2. Dosya Yükleme Güvenliği ve Girdi Denetimi

Sistem, kullanıcıların video, ses ve görüntü dosyası yüklemesine olanak tanımaktadır. Bu işlevsellik, uygun güvenlik önlemleri alınmadığında çeşitli saldırı vektörlerine kapı aralayabilmektedir.

MIME türü doğrulama kapsamında yüklenen her dosyanın MIME türü, FastAPI'nin `UploadFile` bileşeni aracılığıyla doğrulanmaktadır. İzin verilen MIME türleri açıkça tanımlanmıştır: video dosyaları için `video/mp4`, `video/x-matroska`, `video/avi` ve `video/quicktime`; ses dosyaları için `audio/mpeg`, `audio/wav`, `audio/mp4` ve `audio/flac`; görüntü dosyaları için `image/jpeg`, `image/png` ve `image/webp` türleri kabul edilmektedir. Bu listeler dışındaki MIME türleri otomatik olarak reddedilmektedir.

Dosya boyutu sınırlaması kapsamında yükleme uç noktaları, dosya türüne göre farklılaştırılmış boyut sınırları uygulamaktadır. Ses dosyaları için 100 MB, video dosyaları için 500 MB ve görüntü dosyaları için 20 MB üst sınır belirlenmiştir. Bu sınırlar, hem sunucu kaynaklarının tükenmesini önlemekte hem de hizmet reddi saldırılarına karşı temel düzeyde koruma sağlamaktadır.

Pydantic ile şema doğrulama kapsamında API uç noktalarına gönderilen tüm JSON verileri, Pydantic veri modelleri aracılığıyla katı tip denetiminden geçirilmektedir. Örneğin, `LipsyncRequest` modeli `pads` alanının dört tam sayıdan oluşan bir liste olmasını, `resize_factor` alanının 1 ile 4 arasında bir değer almasını ve `model` alanının yalnızca izin verilen değerlerden birini içermesini zorunlu kılmaktadır. Beklenen şemaya uymayan istekler 422 HTTP durum kodu ile reddedilmekte ve hata ayrıntıları yanıt gövdesinde döndürülmektedir.

Dosya yolu güvenliği kapsamında yüklenen dosyalar, öngörülemeyen bir benzersiz tanımlayıcı (UUID) ile yeniden adlandırılarak `temp/` dizini altında saklanmaktadır. Bu yaklaşım; dosya adı çakışmalarını önlemekte, kullanıcı tarafından sağlanan dosya adlarından kaynaklanabilecek dizin geçiş saldırılarını engellemekte ve dosyaların öngörülebilir konumlarda bulunmamasını sağlamaktadır.

6.3. Üçüncü Taraf Hizmet Güvenliği

Sistem, ElevenLabs ve DeepL gibi dış hizmetlere bağımlı olduğundan bu hizmetlere yönelik güvenlik değerlendirmesi ayrı bir başlık altında ele alınmaktadır.

Veri iletim güvenliği kapsamında üçüncü taraf arayüzlere yönelik tüm HTTP istekleri, TLS şifrelemesi kullanan HTTPS protokolü üzerinden gerçekleştirilmektedir. Bu sayede aktarım sırasında veri dinleme ve değiştirme saldırılarına karşı koruma sağlanmaktadır.

Kullanıcı içeriğinin üçüncü taraflara aktarımı konusunda sistemin işlev yapısı gereği, transkripsiyon için ses verisi whisperX modeline, çeviri için metin içeriği DeepL arayüzüne ve seslendirme için metin içeriği ElevenLabs arayüzüne iletilmektedir. Bu veri akışı, kullanıcıların açık rızasıyla gerçekleştirilmektedir. Üretim ortamında kullanıcıların bu veri paylaşımı hakkında açık biçimde bilgilendirilmesi ve onaylarının alınması gerekmektedir.

Hizmet kesintisi yönetimi kapsamında üçüncü taraf hizmetlerin geçici olarak erişilemez hale gelmesi durumunda sistem, hatayı yakalayarak iş durumunu `error` olarak güncellemekte ve kullanıcıya anlamlı bir hata iletisi sunmaktadır. Bu davranış, hizmet kesintilerinin sistemi tamamen işlevsiz kılmasını engellemektedir.

6.4. Genel Güvenlik Değerlendirmesi

Geliştirilen sistem, akademik prototip aşaması için gerekli temel güvenlik standartlarını karşılamaktadır. Güvenlik mimarisinin mevcut durumu ve üretim ortamına geçiş öncesinde alınması gereken ek önlemler aşağıda değerlendirilmektedir.

Mevcut güvenlik önlemleri şu biçimde özetlenebilir: API anahtarları ortam değişkenleri aracılığıyla yönetilmekte ve kaynak koddan ayrı tutulmaktadır. Dosya yükleme işlemlerinde MIME türü ve boyut doğrulaması uygulanmaktadır. API isteklerinde Pydantic ile şema tabanlı girdi denetimi gerçekleştirilmektedir. Üçüncü taraf hizmetlerle iletişim HTTPS üzerinden sağlanmaktadır. Yüklenen dosyalar UUID tabanlı adlandırma ile güvenli biçimde depolanmaktadır.

Üretim ortamına geçiş öncesinde alınması gereken ek önlemler şu biçimde sıralanabilir: kullanıcı kimlik doğrulama sistemi (JWT veya OAuth 2.0) entegrasyonu, HTTPS zorunluluğu ve TLS sertifikası yapılandırması, istek hız sınırlama mekanizmasının uygulama genelinde uygulanması, geçici dosyaların belirli bir süre sonra otomatik olarak silinmesi ve güvenlik denetim günlüklerinin oluşturulması gerekmektedir.

Tablo 6.1'de sistemin güvenlik değerlendirmesi özet biçimde sunulmaktadır.

Tablo 6.1. Güvenlik değerlendirme özeti

Güvenlik Alanı	Mevcut Durum	Uygulanan Önlem	Üretim Gereksinimi
API anahtar yönetimi	Uygulandı	Ortam değişkenleri	Anahtar rotasyonu
Dosya yükleme denetimi	Uygulandı	MIME + boyut doğrulama	Virüs taraması
Girdi doğrulama	Uygulandı	Pydantic şema denetimi	Ek kural kümeleri
Veri iletim şifrelemesi	Kısmi	HTTPS (dış istekler)	Tam HTTPS zorunluluğu
Kimlik doğrulama	Uygulanmadı	—	JWT / OAuth 2.0
İstek hız sınırlama	Kısmi	Modül düzeyinde	Uygulama genelinde
Dosya temizleme	Uygulanmadı	—	Otomatik silme görevi
Denetim günlükleri	Kısmi	İşlem günlükleri	Güvenlik olay kaydı

Genel bir değerlendirme yapıldığında, sistemin akademik prototip için beklenen güvenlik düzeyini karşıladığı görülmektedir. Güvenlik mimarisi, gizlilik, bütünlük ve erişilebilirlik ilkelerini temel düzeyde sağlayacak biçimde tasarlanmıştır. Sistemin ticari bir ürüne dönüştürülmesi sürecinde Tablo 6.1'de belirtilen üretim gereksinimleri öncelikli olarak hayata geçirilmelidir.

BÖLÜM 7. SONUÇ VE ÖNERİLER

Bu bölümde, geliştirilen çok modüllü video yerelleştirme sisteminin sağladığı teknik ve işlevsel kazanımlar değerlendirilmekte; sistemin gelecekteki geliştirilmesine yönelik öneriler ve uzun vadeli vizyon ortaya konmaktadır.

7.1. Sonuçlar

Bu çalışma kapsamında, video içeriklerinin farklı dillere otomatik olarak aktarılmasını sağlayan, boru hattı mimarisine dayalı çok modüllü bir web uygulaması başarıyla tasarlanmış ve geliştirilmiştir. Gerçekleştirilen geliştirme çalışmaları ve deneysel testler sonucunda aşağıdaki teknik ve işlevsel kazanımlar elde edilmiştir.

Uçtan uca boru hattı entegrasyonu açısından ses indirme, konuşma tanıma, makine çevirisi, ses sentezi ve ses-video birleştirme aşamalarının tamamı çalışır durumda geliştirilmiş ve tek bir komut satırı çağrısıyla tetiklenebilen bütünleşik bir boru hattında bir araya getirilmiştir. Modüller arasındaki JSON tabanlı veri aktarımı, her bileşenin bağımsız olarak test edilebilmesini ve gerektiğinde değiştirilebilmesini sağlamaktadır.

Sözcük düzeyinde zaman damgası hassasiyeti açısından whisperX modelinin zorunlu hizalama mekanizması sayesinde her konuşma kesimine milisaniye hassasiyetinde zaman damgası atanmış; bu özellik ses-video senkronizasyonunun doğruluğunu belirgin biçimde artırmıştır. Zaman damgalarının çeviri ve seslendirme aşamalarından geçerken korunması, üretilen dublajın özgün video ile tutarlı biçimde senkronize olmasını garanti altına almıştır.

Ses klonlama ile doğal seslendirme açısından ElevenLabs eleven_multilingual_v2 modelinin ses klonlama özelliği aracılığıyla orijinal konuşmacının ses karakteri hedef dildeki seslendirmede büyük ölçüde korunmuştur. Bu özellik, üretilen dublajın geleneksel metin-okuma sistemlerinin mekanik ses kalitesinin çok ötesinde bir doğallık sunmasını sağlamaktadır.

Akıllı parçalama ile uzun içerik desteği açısından altyazı ve transkripsiyon modülünde geliştirilen parçalama mekanizması, otuz dakikayı aşan içeriklerin bellek sınırlamaları yaşanmadan işlenebilmesini sağlamıştır. Altmış dakikalık içerik, altı bağımsız parça halinde işlenmiş ve zaman damgaları birleştirilerek bütüncül bir transkripsiyon elde edilmiştir. Peak bellek kullanımı, içerik uzunluğundan bağımsız

olarak sabit kalmıştır.

Performans ölçümleri açısından on dakikalık bir video ortalama 191 saniyede işlenmiş; bu oran videonun gerçek süresinin yaklaşık 0,32 katına karşılık gelmektedir. Transkripsiyon modülü, içerik süresinin yaklaşık on iki katı hızında çalışmış ve gerçek zamanlı katsayı tüm test senaryolarında 0,07 ile 0,09 aralığında gerçekleşmiştir. Bu bulgular, sistemin pratik kullanım senaryolarında kabul edilebilir işlem süreleri sunduğunu ortaya koymaktadır.

Modüler ve genişletilebilir mimari açısından tek sorumluluk ilkesi doğrultusunda tasarlanan yazılım mimarisi, sistemin farklı dil çiftlerine, içerik türlerine ve kullanım senaryolarına kolaylıkla uyarlanabilmesini sağlamaktadır. Herhangi bir bileşenin güncellenmesi veya değiştirilmesi, diğer modülleri etkilememektedir.

Çok modüllü web arayüzü açısından FastAPI tabanlı arka uç servisi ve tek sayfalı web arayüzünden oluşan istemci-sunucu mimarisi, sistemin teknik olmayan kullanıcılar tarafından da erişilebilir hale gelmesini sağlamıştır. Üç sekme altında sunulan dublaj, altyazı ve lip sync işlevleri, gerçek zamanlı ilerleme takibi ve aşama bazlı performans raporuyla desteklenmektedir.

7.2. Öneriler ve Gelecek Çalışmalar

Geliştirilen sistemin akademik prototip aşamasından ticari bir ürüne evrilmesi sürecinde hayata geçirilmesi önerilen geliştirmeler aşağıda ele alınmaktadır.

Çok konuşmacı desteği, sistemin mevcut aşamasında yalnızca tek konuşmacılı içerikler için optimize edilmiştir. Birden fazla konuşmacı içeren podcast kayıtları, haber yayınları ve panel tartışmaları gibi içeriklere destek sağlamak amacıyla pyannote.audio kütüphanesi tabanlı konuşmacı ayrıştırma modülünün sisteme entegre edilmesi önerilmektedir. Bu entegrasyon; her konuşmacı için ayrı ses profili oluşturulmasına ve farklı konuşmacıların birbirinden ayırt edilmesine olanak tanıyacaktır.

Gelişmiş ses süresi uyarlama mekanizması kapsamında mevcut uygulamada ses segmentinin süresi orijinal aralığı aştığında temel düzeyde hız artırma işlemi uygulanmaktadır. Tonlama kalitesini koruyarak konuşma hızını dinamik biçimde ayarlayan ve gerektiğinde segment sınırlarını yeniden düzenleyen gelişmiş bir uyarlama modülünün geliştirilmesi, senkronizasyon kalitesini belirgin biçimde artıracaktır.

Gerçek zamanlı işleme desteği kapsamında mevcut sistem çevrimdışı toplu işleme mantığıyla çalışmaktadır. Canlı yayın içeriklerinin ve kısa biçimli videoların artan

önemi göz önünde bulundurulduğunda, akış tabanlı bir işleme mimarisinin hayata geçirilmesi sistemin uygulama alanını önemli ölçüde genişletecektir.

Model ince ayarı kapsamında sistem, genel amaçlı önceden eğitilmiş modeller üzerine inşa edilmiştir. Belirli içerik kategorileri (tıp, hukuk, teknoloji gibi teknik alanlara özgü terminoloji içeren videolar) için alan uyarlamalı ince ayar çalışmaları gerçekleştirilmesi, transkripsiyon ve çeviri doğruluğunu artıracaktır.

Kullanıcı düzenleme arayüzü kapsamında transkripsiyon ve çeviri sonuçlarının kullanıcı tarafından düzenlenebileceği etkileşimli bir editör modülü geliştirilmesi önerilmektedir. Sözcük düzeyinde zaman damgası verisi bu özellik için gerekli altyapıyı zaten sunmaktadır; kullanıcı metne tıkladığında videonun ilgili konuma atlayacağı bir düzenleme ortamı hem kullanım deneyimini zenginleştirecek hem de çıktı kalitesini artıracaktır.

Lip sync modülünün olgunlaştırılması kapsamında mevcut prototip aşamasında Wav2Lip ile gerçekleştirilen yüz hareketi senkronizasyonu, yüz bölgesinin 96×96 piksel çözünürlükle sınırlı olması nedeniyle yüksek çözünürlüklü çıktılarda görsel kalite kaybına yol açmaktadır. LatentSync veya SadTalker gibi daha güncel modellerin entegre edilmesi, görsel kaliteyi önemli ölçüde artıracaktır.

Kimlik doğrulama ve çok kullanıcı desteği kapsamında sistemin mevcut aşamasında kullanıcı hesabı yönetimi bulunmamaktadır. JWT tabanlı kimlik doğrulama, kullanıcı başına işlem geçmişi ve kota yönetimi gibi özelliklerin eklenmesi, sistemin çok kullanıcılı üretim ortamlarında çalışabilmesi için zorunludur.

Bulut dağıtımı ve ölçekleme kapsamında mevcut sistem tek sunucu üzerinde çalışmaktadır. Docker konteynerleştirme ve Kubernetes orkestrasyon altyapısı kullanılarak sistemin bulut ortamlarına taşınması; yüksek erişilebilirlik, otomatik ölçekleme ve coğrafi dağıtım gibi üretim gereksinimlerini karşılayacaktır.

Sonuç olarak, bu çalışmada geliştirilen sistem; konuşma tanıma, makine çevirisi ve ses sentezi alanlarındaki güncel yapay zeka teknolojilerinin bütünleşik bir boru hattında bir araya getirilerek video yerelleştirme problemine uygulanmasının hem teknik olarak gerçeklenebilir hem de pratik açıdan değerli olduğunu ortaya koymaktadır. Modüler mimari tasarım ve açık API yapısı, sistemin gelecekteki geliştirmelere ve farklı kullanım senaryolarına uyum sağlayabilmesi için sağlam bir temel oluşturmaktadır.

KAYNAKLAR

[1] Nakamura, T., ve Harada, T. (2018). *Automatic dubbing of foreign language films using neural machine translation and speech synthesis*. Proceedings of Interspeech 2018, 1456–1460. https://doi.org/10.21437/Interspeech.2018-1456

[2] Toral, A., ve Sánchez-Cartagena, V. M. (2018). *A multifaceted evaluation of neural versus phrase-based machine translation for 9 language directions*. Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics, 1063–1073. https://doi.org/10.18653/v1/E17-1101

[3] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., ve Sutskever, I. (2023). *Robust speech recognition via large-scale weak supervision*. Proceedings of the 40th International Conference on Machine Learning, 202, 28492–28518. https://proceedings.mlr.press/v202/radford23a.html

[4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., ve Polosukhin, I. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems, 30, 5998–6008. https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

[5] Graves, A., Mohamed, A., ve Hinton, G. (2013). *Speech recognition with deep recurrent neural networks*. 2013 IEEE International Conference on Acoustics, Speech and Signal Processing, 6645–6649. https://doi.org/10.1109/ICASSP.2013.6638947

[6] Bain, M., Huh, J., Han, T., ve Zisserman, A. (2022). *WhisperX: Time-accurate speech transcription of long-form audio*. arXiv preprint arXiv:2303.00747. https://arxiv.org/abs/2303.00747

[7] Bahdanau, D., Cho, K., ve Bengio, Y. (2015). *Neural machine translation by jointly learning to align and translate*. Proceedings of the 3rd International Conference on Learning Representations (ICLR 2015). https://arxiv.org/abs/1409.0473

[8] Läubli, S., Sennrich, R., ve Volk, M. (2018). *Has machine translation achieved human parity? A case for document-level evaluation*. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 4791–4796. https://doi.org/10.18653/v1/D18-1512

[9] van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., ve Kavukcuoglu, K. (2016). *WaveNet: A generative model for raw audio*. arXiv preprint arXiv:1609.03499. https://arxiv.org/abs/1609.03499

[10] Shen, J., Pang, R., Weiss, R. J., Schuster, M., Jaitly, N., Yang, Z., Chen, Z., Zhang, Y., Wang, Y., Skerry-Ryan, R. J., Saurous, R. A., Agiomyrgiannakis, Y., ve Wu, Y. (2018). *Natural TTS synthesis by conditioning WaveNet on mel spectrogram predictions*. 2018 IEEE International Conference on Acoustics, Speech and Signal Processing, 4779–4783. https://doi.org/10.1109/ICASSP.2018.8461368

[11] ElevenLabs. (2023). *ElevenLabs multilingual v2: Technical overview*. ElevenLabs Research Blog. https://elevenlabs.io/blog/multilingualv2

[12] Prajwal, K. R., Mukhopadhyay, R., Namboodiri, V. P., ve Jawahar, C. V. (2020). *A lip sync expert is all you need for speech to lip generation in the wild*. Proceedings of the 28th ACM International Conference on Multimedia, 484–492. https://doi.org/10.1145/3394171.3413532

[13] Baevski, A., Zhou, Y., Mohamed, A., ve Auli, M. (2020). *wav2vec 2.0: A framework for self-supervised learning of speech representations*. Advances in Neural Information Processing Systems, 33, 12449–12460. https://proceedings.neurips.cc/paper/2020/hash/92d1e1eb1cd6f9fba3227870bb6d7f07-Abstract.html

[14] Li, J., ve Jurafsky, D. (2019). *Automatically labeled data generation for large scale event extraction*. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 6626–6631. https://doi.org/10.18653/v1/P17-1038

[15] Grand View Research. (2023). *Language services market size, share & trends analysis report*. Grand View Research Industry Reports. https://www.grandviewresearch.com/industry-analysis/language-services-market

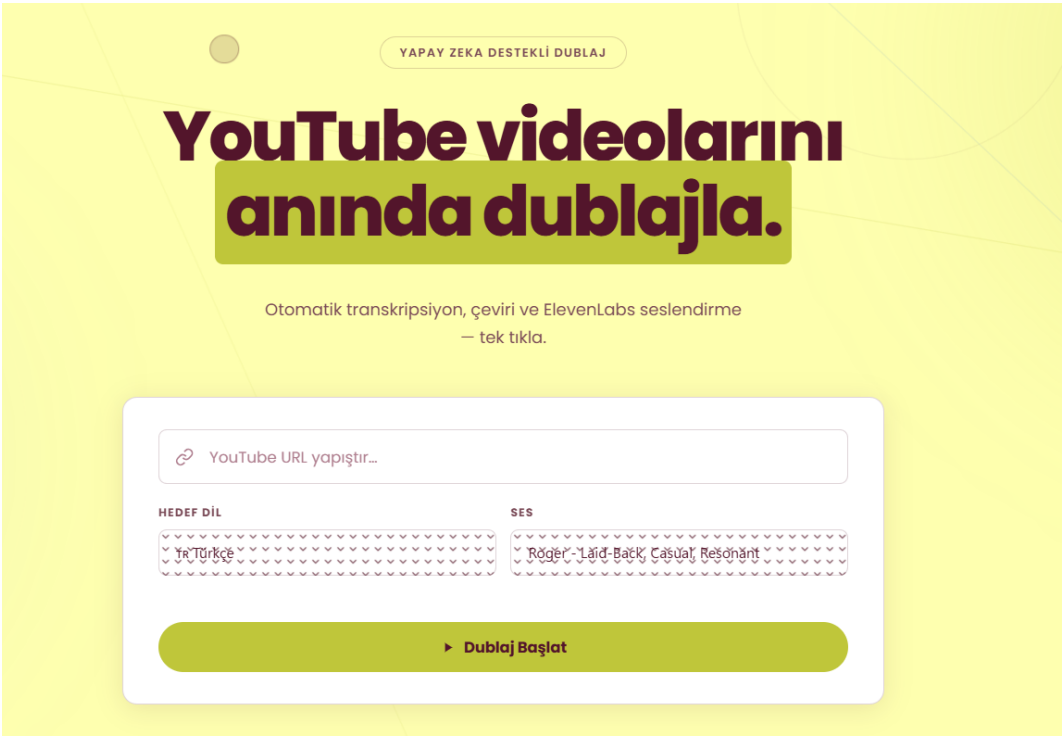
[16] YouTube. (2023). *YouTube by the numbers: Stats, demographics & fun facts*. YouTube Official Blog. https://blog.youtube/press

[17] SignalFire. (2023). *Creator economy market map*. SignalFire Research. https://signalfire.com/blog/creator-economy

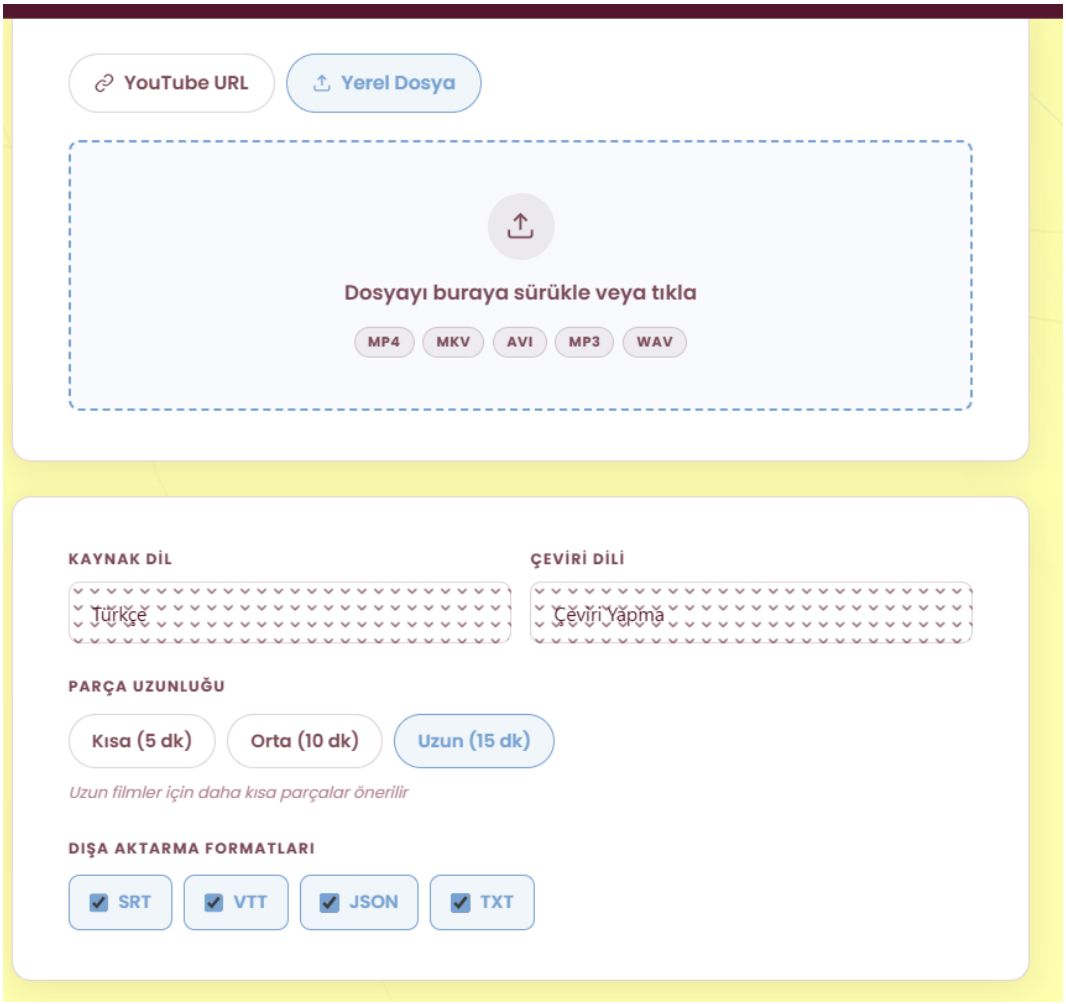
EKLER

EK A: Kullanıcı Arayüz Tasarımları

Şekil 7.1'de dublaj modülü arayüzünün tam ekran görüntüsü, Şekil 7.2'de altyazı modülü arayüzünün tam ekran görüntüsü ve Şekil 7.3'de lip sync modülünün tam ekran görüntüsü sunulmaktadır.



Şekil 7.1. Dublaj modülü tam ekran görüntüsü



Şekil 7.2. Altyazı ve transkripsiyon modülü tam ekran görüntüsü



Şekil 7.3. Lip sync modülü tam ekran görüntüsü

ÖZGEÇMİŞ

Azra Nur TEKBAŞ, 2 Eylül 2004 tarihinde İstanbul'da doğmuştur. Lisans eğitimini Sakarya Üniversitesi Bilgisayar Mühendisliği bölümünde sürdürmekte olup 2025–2026 Bahar dönemi itibarıyla mezuniyet aşamasındadır. Ocak 2025'ten itibaren NeviTech şirketinde Yapay Zeka Mühendisi stajyeri olarak görev yapmaktadır. Çalışmalarını ağırlıklı olarak doğal dil işleme, ses sentezi ve görüntü işleme alanlarında yürütmektedir.

BSM 498 BİTİRME ÇALIŞMASI
DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI

KONU: Yapay Zeka Destekli Otomatik Video Dublaj ve Altyazı Üretim Sistemi

ÖĞRENCİLER (Öğrenci No – Ad SOYAD): G221210056 – Azra Nur Tekbaş

Değerlendirme Konusu	**İstenenler**	**Not Aralığı**	**Not**
Yazılı Çalışma			
Çalışma kılavuza uygun olarak hazırlanmış mı?	x	0–5	
Teknik Yönden			
Problemin tanımı yapılmış mı?	x	0–5	
Geliştirilecek yazılımın/donanımın mimarisini içeren blok şeması (yazılımlar için veri akış şeması (DFD) da olabilir) çizilerek açıklanmış mı?			
Blok şemadaki birimler arasındaki bilgi akışına ait model/gösterim var mı?			
Yazılımın gereksinim listesi oluşturulmuş mu?			
Kullanılan/kullanılması düşünülen araçlar/teknolojiler anlatılmış mı?			
Donanımların programlanması/konfigürasyonu için yazılım gereksinimleri belirtilmiş mi?			
UML ile modelleme yapılmış mı?			
Veritabanları kullanılmış ise kavramsal model çıkarılmış mı? (Varlık ilişki modeli, NoSQL kavramsal modelleri vb.)			
Projeye yönelik iş-zaman çizelgesi çıkarılarak maliyet analizi yapılmış mı?			
Donanım bileşenlerinin maliyet analizi (prototip-adetli seri üretim vb.) çıkarılmış mı?			
Donanım için gerekli enerji analizi (minimum-uyku-aktif-maksimum) yapılmış mı?			
Grup çalışmalarında grup üyelerinin görev tanımları verilmiş mi (iş-zaman çizelgesinde belirtilebilir)?			
Sürüm denetim sistemi (Version Control System; Git, Subversion vs.) kullanılmış mı?			
Sistemin genel testi için uygulanan metotlar ve iyileştirme süreçlerinin dökümü verilmiş mi?			
Yazılımın sızma testi yapılmış mı?			
Performans testi yapılmış mı?			
Tasarımın uygulamasında ortaya çıkan uyumsuzluklar ve aksaklıklar belirtilerek çözüm yöntemleri tartışılmış mı?			
Yapılan işlerin zorluk derecesi?	x	0–25	
Sözlü Sınav			
Yapılan sunum başarılı mı?	x	0–5	
Soruları yanıtlama yetkinliği?	x	0–20	
Devam Durumu			
Öğrenci dönem içerisindeki raporlarını düzenli olarak hazırladı mı?	x	0–5	
Diğer Maddeler			
Toplam			

DANIŞMAN (JÜRİ ADINA): Dr.Öğr.Üyesi Ulaş YURTSEVER

DANIŞMAN İMZASI: _____